Modelo de aprendizaje mediante redes neuronales convolucionales para la detección de patologías como la mancha negra y roña en la fruta del aguacate

Herrera Aguiar Axel Samuel y Marin Alquinga Josue Isaac

Departamento de Ciencias de la Computación

Carrera de Software

Trabajo de integración curricular, previo a la obtención del título de Ingeniero de Software

Ing. Chicaiza Angamarca, Doris Karina, Mgtr.

17 de Julio del 2026



Certificado de análisis
Compilatio Magister+ | ESPE-ECU

7a. Trabajo IntegraciónCurricular_Herrera_Marin
ID : 20fc31e575f43b7923e69588f4c37156d47067fb

5%
Textos sospechosos

Nombre del fichero : 7a. Trabajo IntegraciónCurricular_Herrera_Marin.txt
Tamaño del archivo original : 5,26 MB
Número de palabras : 18.192

Depositante : DORIS KARINA CHICAIZA ANGAMARCA
Fecha de depósito : 23 de septiembre de 2026
Tipo de carga : interface
fecha de fin de análisis : 23 de septiembre de 2026

Resumen (sección 1/2)

Localización de los textos sospechosos en el documento :

Incluido en el porcentaje de textos sospechosos :

Similitudes 3%
Pasajes con similitudes a fuentes encontradas en diferentes colecciones.

Detección de IA 2%
Textos estilísticamente próximos a un texto generado por una IA.
Este índice es un indicador y no una prueba. Comprueba con el autor si domina los conocimientos mencionados en el documento.

Validar únicamente en FirmaEC.
Firmado electrónicamente por:
DORIS KARINA
CHICAIZA ANGAMARCA

Ing. Chicaiza Angamarca, Doris Karina, Mgtr.

Directora

Departamento de Ciencias de la Computación

Carrera de Software

Certificación

Certifico que el trabajo de titulación: "**Modelo de aprendizaje mediante Redes Neuronales Convolucionales para la detección de patologías como la mancha negra y roña en la fruta del aguacate**" fue realizado por los señores Herrera Aguiar Axel Samuel y Marin Alquinga Josue Isaac, el mismo que cumple con los requisitos legales, teóricos, científicos, técnicos y metodológicos establecidos por la Universidad de las Fuerzas Armadas ESPE, además fue revisado y analizado en su totalidad por la herramienta de prevención y/o verificación de similitud de contenidos; razón por la cual me permito acreditar y autorizar para que se lo sustente públicamente.

Sangolquí, 17 de Julio del 2026

Validar únicamente en FirmaEC.
Firmado electrónicamente por:
DORIS KARINA
CHICAIZA ANGAMARCA

Ing. Chicaiza Angamarca, Doris Karina, Mgtr.

Directora

C.C.: 0502986508

Departamento de Ciencias de la Computación

Carrera de Software

Responsabilidad de Autoría

Nosotros, Herrera Aguiar Axel Samuel y Marin Alquinga Josue Isaac, con cédulas de ciudadanía n° 1726791641 y n° 0504345927, declaramos que el contenido, ideas y criterios del trabajo de titulación: Modelo de aprendizaje mediante Redes Neuronales Convolucionales para la detección de patologías como la mancha negra y roña en la fruta del aguacate es de nuestra autoría y responsabilidad, cumpliendo con los requisitos legales, teóricos, científicos, técnicos, y metodológicos establecidos por la Universidad de las Fuerzas Armadas ESPE, respetando los derechos intelectuales de terceros y referenciando las citas bibliográficas.

Sangolquí, 17 de Julio del 2026

Herrera Aguiar Axel Samuel

C.C.: 1726791641

Marin Alquinga Josue Isaac

C.C.: 0504345927

Departamento de Ciencias de la Computación

Carrera de Software

Autorización de Publicación

Nosotros, Herrera Aguiar Axel Samuel y Marin Alquinga Josue Isaac, con cédulas de ciudadanía n° 1726791641 y n° 0504345927, autorizamos a la Universidad de las Fuerzas Armadas ESPE publicar el trabajo de titulación: Modelo de aprendizaje mediante Redes Neuronales Convolucionales para la detección de patologías como la mancha negra y roña en la fruta del aguacate en el Repositorio Institucional, cuyo contenido, ideas y criterios son de nuestra responsabilidad.

Sangolquí, 17 de Julio del 2026

Herrera Aguiar Axel Samuel

C.C.: 1726791641

Marin Alquinga Josue Isaac

C.C.: 0504345927

Dedicatoria

Yo, Josué Isaac Marín Alquinga, dedico este trabajo primeramente a Dios, por la fuerza y ese aliento de vida que me da cada día para seguir adelante, y por ser mi guía y sostén en cada paso de este camino.

A mis padres, Enma Alquinga y Marco Marín, por ese sacrificio silencioso, su fe inquebrantable en mí y su apoyo incondicional a lo largo de toda mi formación. Gracias por enseñarme, con su ejemplo, que la perseverancia y la dedicación, de la mano de Dios, son las claves para alcanzar cualquier meta. Todo lo que soy se lo debo a ustedes.

A mis hermanos Damaris y Daniel Marin, quienes con su cariño y compañía me han enseñado que nada es imposible cuando se lucha con el corazón. Y a todas las personas que creyeron en mí, incluso en los momentos más difíciles: este logro también es suyo.

Yo, Axel Samuel Herrera Aguiar, dedico este trabajo a Dios por darme esperanza para afrontar la vida y por los obstáculos que me ha presentado, los cuales me han permitido crecer y mejorar cada día.

A mis padres, Lucila Aguiar y Marco Herrera, cuyo apoyo constante y amor incondicional hicieron posible mi culminación de esta etapa. A mi Abuelo, Víctor Aguiar, porque su presencia y memoria han sido un faro en mi vida académica, a pesar de no haber podido ver el final de este camino.

De manera especial, a mis hermanos Elian y Ariel Herrera, quienes me ayudaron a seguir adelante cuando el trayecto se tornaba cuesta arriba. Y finalmente, a mis amigos por brindarme su confianza y creer en mi incondicionalmente. La gratitud es la memoria del corazón, y el mío siempre estará agradecido con cada uno de ustedes

Agradecimiento

Expresamos nuestro más sincero agradecimiento a la Universidad de las Fuerzas Armadas ESPE y, en particular, al Departamento de Ciencias de la Computación, por brindarnos los conocimientos y las herramientas necesarias para nuestra formación profesional.

De manera especial, agradecemos a nuestra directora de tesis, Ing. Doris Karina Chicaiza Angamarca, Mgtr., por su guía, paciencia y valiosos aportes durante el desarrollo de este trabajo de titulación. Su acompañamiento fue esencial para culminar con éxito esta investigación.

Finalmente, agradecemos a nuestros docentes, compañeros y amigos, y a todas las personas que, de una u otra forma, con su apoyo, sus consejos y su compañía, contribuyeron a la realización de este proyecto. A todos ellos, nuestra más sincera gratitud.

Índice de contenidos

Dedicatoria 6

Resumen 15

Capítulo I 17

Introducción 17

Antecedentes del estudio 18

Planteamiento del problema 19

Formulación del problema de investigación 19

Objetivo general 19

Objetivos específicos 19

Justificación e importancia del estudio 20

Estado del Arte 20

Capítulo II 27

Marco teórico 27

Introducción 27

Agricultura de precisión y monitoreo fitosanitario 27

Enfermedades fúngicas en el cultivo de aguacate 28

Mancha negra del aguacate 29

Roña del aguacate 30

Inteligencia artificial aplicada a la agricultura 31

Aprendizaje automático y aprendizaje profundo 32

Visión artificial en el diagnóstico de enfermedades vegetales 34

Redes neuronales convolucionales (CNN) 36

Arquitectura y funcionamiento de las CNN 36

Aplicación de CNN en clasificación de imágenes 38
Modelos de CNN para clasificación de imágenes 38
Modelos CNN tradicionales 38
Modelos CNN eficientes para dispositivos móviles 39
Aplicaciones móviles en el sector agrícola y brecha digital 41
Capítulo III 42
Metodología 42
Enfoque de la investigación 42
Tipo y alcance de la investigación 42
Diseño metodológico 43
Población y muestra 43
Recolección de datos 43
Construcción del conjunto de datos de imágenes 44
Etiquetado y validación de imágenes 44
Preprocesamiento de datos 44
Normalización y aumento de datos 45
División de datos (entrenamiento, validación y prueba) 45
Entrenamiento del modelo CNN 45
Técnicas de evaluación y métricas 47
Precisión 47
Recall 47
F1-score 48
Capítulo IV 48
Desarrollo del sistema propuesto 48
Análisis de requerimientos 48
Requerimientos Funcionales 48

Requerimientos No Funcionales 50
Diagrama de casos de uso 51
Modelo de procesos de negocio 52
Diseño de la arquitectura del sistema 53
Capa de Lógica de Negocio (Business Logic Layer): 54
Esquema de la Base de Datos Local 55
Diseño de la arquitectura del modelo CNN 55
Descripción del Conjunto de datos 56
Arquitectura MobileNetV2 con Transfer Learning 57
Configuración de Hiperparámetros de Entrenamiento 58
Resultados del Entrenamiento y Evaluación 59
Conversión y Optimización a TensorFlow Lite 59
Componentes de la aplicación móvil 60
Módulo de Captura de Imágenes 61
Módulo de Clasificación de Enfermedades 62
Módulo de Visualización de Resultados 63
Módulo de Configuración y Versionamiento 64
Módulo de Resumen y Estadísticas 65
Módulo de Asistente Virtual 68
Tecnologías Utilizadas 68
Tecnologías del Entorno de Entrenamiento del Modelo 69
Tecnologías del Entorno de Desarrollo de la Aplicación Móvil 69
Funcionamiento general del prototipo 70
Flujo de Usuario End-to-End 70
Capítulo V 73
Resultados y validación 73

Escenario y condiciones de prueba 73
Evaluación del modelo CNN 74
Resultados de entrenamiento 74
Resultados de validación y prueba 75
Evaluación del prototipo en campo 78
Análisis de resultados 79
Discusión de resultados 80
Capítulo VI 81
Conclusiones y recomendaciones 81
Conclusiones 81
Recomendaciones y trabajo futuro 83
Referencias 84
Apéndices 87

Índice de tablas

Tabla 1 Síntesis comparativa de estudios sobre detección de enfermedades en frutas mediante aprendizaje profundo. 24

Tabla 2 Comparativa de arquitecturas CNN. 41

Tabla 3 Fases del diseño metodológico para la construcción del modelo. 43

Tabla 4 Requerimientos funcionales del sistema Avocado IA. 49

Tabla 5 Requerimientos no funcionales del sistema Avocado IA. 50

Tabla 6 Organización modular del código fuente por características. 54

Tabla 7 Esquema de la base de datos local SQLite del sistema Avocado IA. 55

Tabla 8 Distribución del conjunto de datos de imágenes por clase y partición. 56

Tabla 9 Técnicas de aumento de datos aplicadas al conjunto de entrenamiento. 56

Tabla 10 Arquitectura detallada del modelo CNN Avocado IA. 58

Tabla 11 Hiperparámetros de configuración del entrenamiento del modelo CNN. 58

Tabla 12 Métricas de evaluación del modelo CNN en el conjunto de test. 59

Tabla 13 Comparación entre el modelo Keras original y el modelo TensorFlow Lite. 60

Tabla 14 Niveles de alerta fitosanitaria de la calculadora de incidencia. 67

Tabla 15 Tecnologías utilizadas en el entorno de entrenamiento del modelo CNN. 69

Tabla 16 Paquetes y tecnologías utilizados en el desarrollo de la aplicación móvil Avocado IA. 69

Tabla 17 Desempeño por clase del modelo en el conjunto de prueba balanceado. 76

Tabla 18 Comparación de arquitecturas en igualdad de condiciones (20 épocas, base congelada). 77

Índice de figuras

Figura 1 Síntomas de mancha negra (Pseudocercospora purpurea) en fruto de aguacate. Fuente: Marais (2007). 29

Figura 2 Síntomas de roña (Sphaceloma perseae) en fruto de aguacate. Fuente: Ávila-Quezada et al. (2003). 30

Figura 3 Arquitectura de CNN 37

Figura 4 Arquitectura AlexNet y ResNet-50 39

Figura 5 Arquitectura de MobileNet-V1 y MobileNet-V2 40

Figura 6 Construcción y validación de la clasificación de las imágenes con el Ing. Guido Sigcha. 44

Figura 7 Diagrama de casos de uso del sistema Avocado IA. 51

Figura 8 Diagrama de procesos de negocio del diagnóstico fitosanitario con Avocado IA. 52

Figura 9 Diagrama general de la arquitectura del sistema Avocado IA. 53

Figura 10 Arquitectura del modelo de clasificación basado en MobileNetV2 con transfer learning. 57

Figura 11 Vista general de la navegación principal de Avocado IA con los seis módulos. 60

Figura 12 Módulo de captura de imágenes: selección desde cámara/galería y vista previa. 61

Figura 13 Resultado de clasificación mostrando diagnóstico, confianza y recomendaciones. ... 63

Figura 14 Módulo de historial mostrando detecciones previas con color por estado. 64

Figura 15 Pantalla de configuración con selector de idioma e información de versión. 65

Figura 16 Dashboard con tarjetas de resumen y gráfico de distribución de enfermedades. 66

Figura 17 Calculadora de incidencia con resultado y nivel de alerta fitosanitaria. 67

Figura 18 Pantalla de Asistente de recomendaciones 68

Figura 19 Diagrama de flujo del usuario end-to-end en el prototipo Avocado IA. 71

Figura 20 Curvas de pérdida, exactitud, precisión y exhaustividad del modelo balanceado durante el entrenamiento. 75

Figura 21 Matriz de confusión del modelo en el conjunto de prueba balanceado. 76

Resumen

En Ecuador, el cultivo de aguacate (Persea americana) sufre por enfermedades fúngicas como la mancha negra y la roña. Actualmente, los agricultores las detectan a simple vista, un proceso lento y propenso a errores que retrasa el control fitosanitario. Para solucionarlo, el presente proyecto busca implementar un modelo de aprendizaje profundo, enfocándose en la optimización para celulares, por lo que es capaz de identificar ambas enfermedades en lo frutos. Y para lograrlo, se armó una base de datos utilizando imágenes y fotografía del cantón Sigchos junto con repositorios públicos, asegurando así 1000 imágenes para cada categoría. Este modelo se entrenó mediante transferencia de aprendizaje con el modelo de MobileNetV2 la cual es pre entrenado en ImageNet, durante este proceso se añadió un clasificador denso y técnicas de aumento de datos. Al momento de evaluarlo con un grupo de prueba de 451 capturas, alcanzó un 96.23% en exactitud y 96.22% en el valor de F1 macro. Concretamente se logró un 94.59% para la enfermedad mancha negra, 95.71% para roña y 98.35% para aguacates sanos. Finalmente, al modelo se lo adapto a TensorFlow Lite. Luego de un proceso medición el modelo tiene un peso ligero de 3.2 MB manteniendo la exactitud del 96.01% provocando que este modelo se integre a la app de Avocado IA, la cual fue desarrollada en Flutter por lo tanto es la que está encargada de realizar el análisis de forma local y sin necesidad de internet. Los resultados demuestran que llevar un diagnóstico fitosanitario accesible y rápido a las zonas rurales es totalmente viable.

Palabras clave: aprendizaje profundo, redes neuronales convolucionales, aguacate, MobileNetV2, detección de enfermedades

Abstract

In Ecuador, avocado (Persea americana) cultivation suffers from fungal diseases such as black spot and scab. Currently, farmers detect them with the naked eye, a slow and error-prone process that delays phytosanitary control. To solve this, the current project seeks to implement a deep learning model focused on mobile optimization, making it capable of identifying both diseases in the fruits. To achieve this, a database was assembled using images and photographs from the Sigchos canton along with public repositories, thereby ensuring 1,000 images for each category. This model was trained using transfer learning with the MobileNetV2 model, which is pre-trained on ImageNet; during this process, a dense classifier and data augmentation techniques were added. On a 451-image test set, the model reached 96.23% accuracy and 96.23% macro F1: 94.59% for black spot, 95.71% for scab, and 98.35% for healthy avocados. Converting it to TensorFlow Lite brought the model down to 3.2 MB, with accuracy at 96.01%. At that size it ships inside Avocado IA, a Flutter app that runs the analysis on the phone. No internet connection required. Ultimately, these findings prove that delivering fast and accessible crop diagnostics to rural farming communities is completely feasible.

Keywords: deep learning, convolutional neural networks, avocado, MobileNetV2, disease detection

Capítulo I

Introducción

Introducción

El cultivo de aguacate pierde cosecha y dinero por enfermedades fúngicas que dañan el fruto, reducen el rendimiento y dificultan su venta. Dos de las más agresivas son la mancha negra (Pseudocercospora purpurea) y la roña (Sphaceloma perseae), que avanzan rápido en plantaciones con poco monitoreo o donde solo se revisa a simple vista. Ese método depende de la visión y la experiencia de cada agricultor que evalúa, así que es subjetivo y se encuentra errores de diagnóstico, y muchas detecciones llegan tarde: cuando la enfermedad ya no se puede controlar o se aplica un mal producto en consecuencia de un mal análisis.

El agricultor no tiene hoy una herramienta para detectar estas enfermedades a tiempo y sin diagnóstico, los agroquímicos se aplican mal por consecuencia suben los costos, crece el riesgo de fitotoxicidad y se pierde fruta después de la cosecha porque nadie vio el daño a tiempo. Por eso hace falta una solución donde se pueda aplicar la inteligencia artificial que adelante el diagnóstico en el campo y dé un resultado parejo sin importar quién evalúe.

Para eso se propone un modelo de aprendizaje profundo que detecte la mancha negra y la roña en el aguacate, donde el modelo usa redes neuronales convolucionales con transferencia de aprendizaje que reconoce en la propia fotografía los patrones visuales de cada categoría, la meta es darle al agricultor una herramienta de monitoreo por visión por computadora que agilice el diagnóstico, reduzca tiempos como pérdidas y le permita decidir a tiempo en las primeras etapas del cultivo.

Antecedentes del estudio

El cultivo de aguacate es un campo que tiene lugar en la economía tanto en Ecuador como en varias zonas de Latinoamérica. Sin embargo, las enfermedades causadas por hongos son una de las mayores amenazas para la calidad y el rendimiento de las cosechas. Dentro de estos problemas, la mancha negra y la roña destacan por lo rápido que se propagan y por cómo afectan negativamente la venta de la fruta.

Tradicionalmente, identificar estas enfermedades se ha hecho revisando los cultivos a simple vista. Este es un método que recae mucho en la experiencia del agricultor y que tiene claras limitaciones tanto de precisión como de estandarización. Justamente, estas fallas propias del diagnóstico manual son las que han impulsado la búsqueda de herramientas tecnológicas para automatizar y mejorar la detección temprana de las patologías en las plantaciones.

Frente a este panorama, la inteligencia artificial, y específicamente las redes neuronales convolucionales (CNN), han probado ser herramientas muy útiles para clasificar imágenes agrícolas. Varios estudios ya han analizado el uso de modelos de aprendizaje profundo para identificar enfermedades en cultivos de manzana, tomate y café, logrando resultados muy alentadores tanto en la precisión como en la velocidad del diagnóstico.

Sin embargo, la investigación sobre tecnología para la detección de mancha negra y roña de aguacate ha siso escasamente investigada, por lo que se evidencia claramente una brecha e conocimiento que el presente trabajo quiere demostrar mediante el desarrollo de un modelo de categorización basado en CNN, implementado dentro de una app móvil accesible para los usuarios finales que son los agricultores.

Planteamiento del problema

La detección de enfermedades de tipo fúngicas como mancha negra o la roña en el cultivo de aguacate depende de inspecciones visuales realizadas por los agricultores dentro del campo, el cual es un proceso subjetivo y es propenso a errores humanos. Por lo tanto, esta limitación causa que los diagnósticos sean de baja calidad o que se llegue a complicar al cumplir medidas de control de tiempo facilitando que las enfermedades se sigan expandiendo.

No contar con herramientas tecnológicas accesibles para identificar estas enfermedades de forma rápida y exacta genera problemas en el monitoreo fitosanitario. Además, esta carencia provoca que se utilicen mal los agroquímicos y termina perjudicando tanto el rendimiento de la cosecha como la calidad comercial del aguacate en el cantón de Sigchos. Por todo esto, surge la necesidad de crear un sistema automático que ayude a detectar estas patologías a tiempo.

Formulación del problema de investigación

¿Es viable construir un modelo de aprendizaje profundo, basado en redes neuronales convolucionales, capaz de detectar de forma automatizada la mancha negra y la roña en frutos de aguacate y de integrarse en una aplicación móvil accesible para los agricultores en campo?

Objetivo general

Desarrollar un modelo de aprendizaje profundo basado en visión por computadora que detecte de forma temprana la roña y la mancha negra en el fruto del aguacate.

Objetivos específicos

- Revisar el estado del arte sobre detección de enfermedades fúngicas en frutas, para fundamentar el diseño del modelo.
- Construir un conjunto de 3000 imágenes del fruto de aguacate divididas en tres clases 1000 con mancha negra, 1000 con roña y 1000 sanas, etiquetadas y validadas para el entrenamiento.

- Entrenar el modelo con técnicas de aprendizaje automático y profundo para que reconozca los patrones visuales de los frutos afectados por roña y mancha negra y los clasifique de forma automática.
- Integrar el modelo entrenado en una aplicación móvil que permita a los usuarios finales detectar las enfermedades en tiempo real.

Justificación e importancia del estudio

La mancha negra y la roña causan pérdidas económicas y productivas en el cultivo de aguacate; ahí está la relevancia del problema. Actualmente el diagnóstico recae en la inspección visual manual, un método cuya precisión y rapidez son limitadas y que, al retrasar la detección, favorece la propagación de estas enfermedades.

Frente a esta necesidad, el presente trabajo propone Avocado IA, un prototipo de aplicación móvil para diagnóstico fitosanitario que procesa el modelo directamente en el teléfono del agricultor y funciona sin requerir conexión a internet.

Estado del Arte

El uso de Deep Learning para diagnosticar enfermedades en frutos ha crecido mucho en los últimos cinco años. Las redes neuronales convolucionales son el enfoque principal para detectar patologías vegetales. Se revisaron artículos de Scopus e IEEE Xplore entre 2019 y 2024 para identificar tendencias y vacíos en la investigación.

El cultivo de manzana ha sido utilizado para probar arquitecturas ligeras de detección en una sola etapa debido a la consistencia de las enfermedades foliares. (Jiang et al., 2019) introdujeron INAR-SSD, un detector construido sobre GoogLeNet con módulos Inception y concatenación tipo Rainbow, que logró alrededor de 78.80 % de mAP en un conjunto de datos propio de campo y sentó las bases de las arquitecturas eficientes en escenarios reales. Más adelante,

(Xu & Wang, 2023) propusieron ALAD-YOLO, una variante de YOLOv5s combinada con MobileNetV3 y atención de coordenadas, alcanzando cerca de 90.2 % de mAP con un costo computacional notablemente menor; por su parte, (Zhu et al., 2023) continuaron esta línea con EADD-YOLO, que incorporaba bloques que sobraban de ShuffleNet y obteniendo así un 95.5% de map en el conjunto de datos ALDD, equilibrando la precisión y demanda técnica. Lo interesante de esta línea de trabajos no es solo la mejora en precisión, sino que cada nueva propuesta logra ese aumento sin disparar el costo computacional, lo cual es clave si se piensa en aplicaciones móviles reales.

En cítricos la tendencia va por otro lado: en vez de perseguir arquitecturas cada vez más livianas, los autores han preferido combinar CNN con otros clasificadores o mecanismos de atención para ganar precisión. (Khattak et al., 2021), se entrenó un modelo convolucional con regularización dropout alcanzando así un 94.55% de precisión, distinguiendo así enfermedades en las frutas de naranja y limón. Un poco después (Syed-Ab-Rahman et al., 2021) planteo dos etapas que tenia un valor de F1 de 94% el cual es un resultado similar en magnitud, pero con una arquitectura y propuesta distinta. Sin embargo, (Tan & Le, 2019) llamó la atención porque combino EfficientNet-B0 aplicando regresión logística el cual superó el 99% en condiciones controladas, por lo tanto el mismo estudio dice que la cifra cae significativamente frente a imágenes con ruido es decir con alteraciones en su fondo, lo que deja en duda sobre que tan replicable es el resultado.

Por otro lado el estudio de la uva se inclina mayormente por los detectores de dos etapas trabajando con backbone robustos el cual se refiera a una estructura fundamental que se conecta a los datos y los organiza dentro de un sistema, mientras que (Xie et al., 2020) desarrollaron Fasster DR-IACNN, el cual encontraron una manera de realizar una adaptación de Faster R-CNN con

Inception-v1, Inception-ResNet-v2 y bloques SE, logran oasis un 81.1% de map en un conjunto de sus propios datos de campo.

(Tan & Le, 2019) aplicaron EfficientNet con transferencia de aprendizaje sobre PlantVillage y comunicaron precisiones próximas al 98 %, mientras que (R. Sharma et al., 2023) presentaron VPDN, basado en Faster R-CNN con VGG16, para esca, black rot e sariopsis, alcanzando métricas de detección superiores al 95 %. Se observa una brecha entre los resultados de PlantVillage y los del campo.

Los cultivos tropicales muestran resultados igual de altos, aunque con menos consenso sobre qué arquitectura es la más adecuada. (Singh et al., 2024) realizo una comparación del modelo de CNN con redes pre entrenadas, para hoja de mango, el cual se reflejo un 95% de precisión. Lakshmanan et al. (2024) mejoro una CNN multicapa para detectar patologías en banano obteniendo un resultado cercano a 97%. (Jiang et al., 2019; Kavya et al., 2024) probaron que distintas redes en manzana y se obtuvo un resultado en que coincidió que MobileNet tiene mejor relación entre precisión y eficiencia. (Singh et al., 2024) aplicaron la técnica Spatial Pyramid Pooling a frutas antes de la cosecha y se reportó un 97%. Lo que se desprende de estos trabajos es que el reto ya no es la precisión en condiciones controladas está prácticamente resuelta sino dar con la arquitectura adecuada para cada cultivo y cada contexto de despliegue.

La revisión sistemática de (Goel & Pandey, 1 C.E.) apunta en la misma dirección a mayor escala: documentan un uso creciente de CNN, GAN y transferencia de aprendizaje para diagnosticar enfermedades en frutas, con exactitudes por encima del 90 % en la mayoría de los casos que revisan.

No obstante, los propios autores advierten que esas cifras provienen mayoritariamente de datos controlados, y no de condiciones reales de campo una limitación que, como se vio en los párrafos anteriores, se repite de forma consistente en toda la literatura revisada.

Dentro del contexto ecuatoriano, el antecedente más cercano a esta investigación es el estudio de (Peñafiel et al., 2023), centrado en el uso de aplicaciones móviles con Machine Learning para el manejo de enfermedades del café en la comunidad del Colegio Experimental Intercultural Bilingüe "Jatari Unancha". Una muestra intencional de 38 personas caficultores, docentes y estudiantes reconoció sobre todo tres enfermedades: roya (*Hemileia vastatrix*, 25 %), ojo de gallo (*Mycena citricolor*, 21 %) y alternaria (*Alternaria alternata*, 18 %). El 74 % no sabe reconocer enfermedades del cafeto y el 87 % desconocía que existieran aplicaciones móviles de diagnóstico; de quienes las han usado, el 66 % califica la experiencia de "regular". Esa es la brecha que esta aplicación busca cerrar, en un país donde el acceso a esta tecnología sigue siendo limitado.

(Mohanty et al., 2016) entrenaron AlexNet (Krizhevsky et al., 2017) y GoogLeNet sobre PlantVillage un conjunto abierto de 54.306 imágenes de hojas con 26 enfermedades y 14 especies y llegaron al 99,35 % de exactitud en un conjunto de prueba retenido, sin que un experto tuviera que definir a mano los rasgos a detectar. Ese mismo estudio muestra que la exactitud cae al 31,4 % cuando las imágenes se toman en condiciones distintas a las del entrenamiento.

Sin embargo, el desempeño del modelo disminuye significativamente con imágenes de campo en condiciones variadas, destacando la necesidad de tener un conjunto de datos correspondiente al entorno de cultivo.

(Liakos et al., 2018) hicieron una revisión sobre el uso del aprendizaje automático en agricultura, organizando las aplicaciones de IA en manejo de suelos, agua, pecuario y cultivos, destacando la identificación de enfermedades y malezas como el área más estudiada. Concluyeron

que, si bien algoritmos clásicos como las Máquinas de Vectores de Soporte (SVM) y los Bosques Aleatorios ofrecen buen desempeño con datos tabulares o de sensores climáticos, las redes neuronales profundas son la única opción verdaderamente viable y robusta cuando se manejan datos de alta complejidad y dimensionalidad, como las matrices de píxeles de las imágenes digitales.

La cuestión de trasladar estos modelos a un uso práctico en tiempo real fue abordada por (A. Sharma et al., 2021), quienes explicaron cómo la unión de algoritmos de Machine Learning con dispositivos móviles y tecnologías del Internet de las Cosas (IoT) está mejorando las labores agrícolas directamente en el campo. Los autores subrayan que el valor real de un sistema de diagnóstico fitosanitario no reside únicamente en la precisión del modelo, sino en su capacidad de utilizarse en el punto de inspección, es decir, mientras el agricultor observa la planta. Asimismo, señalan que la mayoría de los sistemas dependen de una conexión permanente a internet para enviar las imágenes a servidores en la nube, arquitectura que resulta poco adecuada en las zonas rurales donde se concentra la producción.

Con base en los trabajos analizados se construyó la **Tabla 1**, que resume los principales estudios considerados y los organiza según su arquitectura, el cultivo objetivo, la precisión reportada y la limitación señalada por los autores del presente trabajo.

Tabla 1
Síntesis comparativa de estudios sobre detección de enfermedades en frutas mediante aprendizaje profundo.

#	Autor y año	Modelo / Arquitectura	Cultivo	Precisión reportada	Limitación identificada
1	Goel y Pandey (2022)	Revisión sistemática (CNN, GAN, TL)	Multifruta	N/A (revisión)	Falta de estandarización entre conjunto de datoss
2	Jiang et al. (2019)	INAR-SSD (GoogLeNet	Manzana	~78.80 % mAP	Requiere hardware potente pese a las mejoras propuestas

		+ Inception + Rainbow)			
3	Xu y Wang (2023)	ALAD-YOLO (YOLOv5s + MobileNetV3 + Coord. Attn.)	Manzana	~90.2 % mAP	Evaluado sobre conjunto de datos controlado, sin prueba en dispositivo móvil
4	Zhu et al. (2023)	EADD-YOLO (YOLOv5 + ShuffleNet + Coord. Attn.)	Manzana	~95.5 % mAP	No incluye validación en aplicación móvil real
5	Khattak et al. (2021)	CNN propia con dropout	Cítricos	~94.55 %	El modelo no se integra en una aplicación funcional
6	Syed-Ab-Rahman et al. (2022)	CNN de dos etapas anchor-based	Cítricos	~94 % F1	Alta demanda computacional para despliegue móvil
7	Çetiner (2022)	EfficientNet-B0 + Regresión Logística	Cítricos	~99.7 %	Métrica sobre conjunto de datos controlado; baja generalización
8	Xie et al. (2020)	Faster DR-IACNN (Inception + SE)	Uva	~81.1 % mAP	Modelo pesado, poco viable para móvil
9	Sharma et al. (2024)	CNN propia + Transfer Learning	Mango	~95 %	Cobertura reducida de enfermedades
10	Lakshmanan et al. (2024)	CNN fine-tuned multicapa	Banano	~97 %	Requiere afinamiento específico por conjunto de datos
11	Hussain et al. (2024)	CNN + Spatial Pyramid Pooling + SSDAE-SVM	Multifruta (postcosecha)	~97 %	Enfocado en postcosecha, no en campo
12	Silva-Peñafiel et al. (2023)	Diagnóstico de uso (encuesta)	Café (Ecuador)	N/A (74 % no reconoce enfermedades)	No propone modelo; solo levanta requerimientos

Nota. Elaboración propia con base en los estudios revisados.

De esta síntesis se desprenden tres patrones:

1. La mayoría de los trabajos con precisiones cercanas al 99 % utilizan conjuntos de datos controlados como PlantVillage, mientras que los estudios con datos de campo tienen precisiones entre el 78 % y el 95 %.
2. Las arquitecturas ligeras MobileNet, ShuffleNet o EfficientNet son las preferidas para dispositivos con recursos limitados.
3. La producción académica se concentra en manzana, uva y cítricos.

El análisis previo permite identificar tres vacíos que motivan de manera directa esta investigación. El primero es la escasez de estudios centrados en el aguacate y, en particular, en patologías como la mancha negra y la roña, que ocasionan un impacto económico relevante en la producción latinoamericana, pero han sido escasamente tratadas con CNN. La distancia entre la precisión informada y el desempeño real no se valida en estudios. El tercero, según con (Peñafiel et al., 2023), se refiere a la ausencia de aplicaciones móviles para el diagnóstico fitosanitario en las zonas rurales del Ecuador.

La presente investigación entrena un modelo MobileNetV2 para clasificar patógenos fúngicos en frutos de aguacate y se lo despliega en una aplicación móvil sin conexión pensada para los agricultores. El planteamiento toma como referencia a (Peñafiel et al., 2023) en el caso del café y traslada esa lógica a un cultivo diferente mediante una arquitectura orientada al despliegue móvil, con el fin de aportar evidencia empírica sobre un nicho hasta ahora poco atendido en el estado del arte.

Capítulo II

Marco teórico

Introducción

El presente capítulo establece las bases teóricas que sustentan el desarrollo de un modelo de aprendizaje profundo para la detección de enfermedades fúngicas en el fruto del aguacate. La producción de aguacate en Latinoamérica es afectada por las enfermedades más comunes que son la mancha negra y la roña, estas enfermedades provocan la reducción de calidad y el rendimiento de las cosechas. Estas enfermedades se detectan únicamente por inspección visual e interpretación personal uno por uno, por lo tanto, se considera un rendimiento lento y subjetivo, ya que en alguno caos pasan desapercibidos y provoca que se retrase el tratamiento fitosanitario.,

Teniendo en cuenta las limitaciones, la visión por computadora permite diagnosticar a partir de una fotografía o captura del fruto. Para fundamentar dicha alternativa, este capítulo desarrolla de manera progresiva los conceptos involucrados: parte de la agricultura de precisión y el monitoreo fitosanitario como marco general, describe las enfermedades fúngicas que afectan al aguacate en particular la mancha negra y la roña y revisa el papel de la inteligencia artificial aplicada a la agricultura. A continuación, se abordan el aprendizaje automático y el aprendizaje profundo, la visión artificial en el diagnóstico de enfermedades vegetales y las redes neuronales convolucionales (CNN), incluyendo su arquitectura y los modelos empleados para la clasificación de imágenes. Finalmente, se analizan las aplicaciones móviles en el sector agrícola y la brecha digital, aspectos clave para el despliegue de la solución propuesta en zonas rurales.

Agricultura de precisión y monitoreo fitosanitario

La necesidad de maximizar la productividad agrícola reduciendo los gastos operativos ha impulsado lo que hoy conocemos como agricultura de precisión (AP). En lugar de tratar un cultivo

completo como un bloque uniforme, la AP se basa en observar y medir las variaciones específicas de cada sector para aplicar tratamientos totalmente focalizados y eficientes. Para alcanzar este nivel de detalle, el monitoreo moderno se apoya en un conjunto de herramientas de recolección de datos. Entre ellas destacan las redes de dispositivos IoT, los vuelos con drones, los sensores remotos y los sistemas de información geográfica, encargados de capturar las variables espaciales y temporales del entorno (A. Sharma et al., 2021). Es precisamente esta información recolectada en campo la que respalda cada intervención, permitiendo que las decisiones de manejo fitosanitario dejen de basarse en la intuición y pasen a estar respaldadas por datos concretos.

Gracias a este enfoque es posible detectar patógenos fúngicos de forma temprana, para reducir así el uso de agroquímicos y planificar mejor las intervenciones por el usuario o usos de químicos. (A. Sharma et al., 2021) señalan al aprendizaje automático y a la maquinaria basada en IoT como sus pilares fundamentales, ya que la incorporación de estas tecnologías fortalece la vigilancia fitosanitaria en cultivos como el aguacate (A. Sharma et al., 2021).

Enfermedades fúngicas en el cultivo de aguacate

El aguacate (Persea americana Mill.) representa un cultivo de gran relevancia en América Latina; sin embargo, su producción se encuentra amenazada por enfermedades ocasionadas por hongos patógenos.

Al respecto, (Marais, 2004) advierte que los costos de producción resultan elevados y que la incidencia de enfermedades es uno de los factores que más limitan la viabilidad del cultivo.

Entre las principales enfermedades fúngicas del aguacate figuran la mancha negra (Pseudocercospora purpurea), la roña (Sphaceloma perseae / Elsinoe perseae), la antracnosis (Colletotrichum gloeosporioides) y la pudrición de raíces (Phytophthora cinnamomi) (Marais, 2007). Todas ellas provocan manchas y pudriciones que perjudican la exportación y el consumo,

por lo que su identificación temprana resulta determinante; en este sentido, los sistemas de visión artificial basados en CNN aportan una alternativa automatizada y escalable.

Mancha negra del aguacate

La mancha negra del aguacate es provocada por el hongo Pseudocercospora purpurea Deighton, del phylum Ascomycota. Este patógeno se describió inicialmente como Cercospora purpurea en hojas del género Persea en Georgia, Estados Unidos, en 1878, y en 1976 fue reasignado al género Pseudocercospora (Marais, 2004). En Sudáfrica, la “mancha negra” es la enfermedad precosecha más severa para aguacates, especialmente Fuerte.

Sus síntomas iniciales son manchas amarillas en hojas y frutos que se convierten en lesiones marrón rojizo con bordes definidos de cuatro milímetros. La enfermedad debilita el tejido, causando orificios irregulares y agrietamiento en los frutos. (Marais, 2004).

Figura 1
Síntomas de mancha negra (Pseudocercospora purpurea) en fruto de aguacate.



Fuente: Marais (2007).

La diseminación de la enfermedad se produce sobre todo mediante las corrientes de viento y la lluvia, así como por la acción de insectos. Las condiciones de alta humedad y temperatura elevada favorecen la infección y, cuando el fruto no recibe una protección fitosanitaria adecuada, las pérdidas económicas pueden alcanzar hasta el 70 % de la producción destinada a exportación (Marais, 2004)

Estas lesiones exhiben rasgos visuales característicos que pueden reconocerse mediante técnicas de visión por computadora. Por sus patrones de imagen bien diferenciados, P. purpurea constituye un caso de estudio idóneo para las tareas de clasificación basadas en CNN.

Roña del aguacate

Figura 2
Síntomas de roña (Sphaceloma perseae) en fruto de aguacate.



Fuente: Ávila-Quezada et al. (2003).

La roña del aguacate es ocasionada por el hongo Sphaceloma perseae Jenkins (teleomorfo: Elsinoe perseae), perteneciente al phylum Ascomycota, clase Dothideomycetes y orden Myriangiales. Esta enfermedad se trato por primera vez en EE.UU en 1918 y el invetigaodr Jenkins

la denomino formalmente en 1934 (Mexicana de Fitopatología et al., 2003). Los síntomas que se presenta son lesiones circulares que se encuentran de color marrón con tonos morados a pasar a un marrón obscuro, presentándose en hojas y frutos deteriorándose con el tiempo (Marais, 2004). Por lo tanto, el fruto es más propenso desde la etapa de fructificación para alcanzar la maduración; por otro las hojas son más resistentes poco después de un mes de obtener el fruto. Los conidios se dispersan por viento, lluvia, rocío e insectos (Mexicana de Fitopatología et al., 2003).

La infección se ve favorecida por una humedad relativa superior al 80 %, temperaturas de frescas a moderadas y lluvias frecuentes durante el crecimiento vegetativo. En huertos de aguacate Hass de Michoacán, México, se registró una incidencia de roña del 97 %, asociada a un daño por trips del 90 % (Mexicana de Fitopatología et al., 2003). Las lesiones de roña presentan rasgos morfológicos propios elevación, textura corchosa y coloración oscura que las distinguen tanto del tejido sano como de las lesiones de mancha negra.

Dicha diferenciación visual hace de la roña una segunda categoría de clasificación apropiada para los modelos de CNN, que complementa la detección de la mancha negra en el sistema propuesto en este trabajo.

Inteligencia artificial aplicada a la agricultura

La inteligencia artificial (IA) puede entenderse como el conjunto de técnicas computacionales destinadas a construir sistemas capaces de ejecutar tareas que habitualmente exigen inteligencia humana, como el reconocimiento de patrones, la toma de decisiones y la interpretación de información visual o textual. En el ámbito agrícola, la IA ha dejado de ser un terreno meramente experimental para convertirse en un componente estratégico del manejo inteligente de cultivos, sobre todo cuando la magnitud del problema supera las posibilidades del monitoreo manual (Liakos et al., 2018).

(Liakos et al., 2018) las aplicaciones de la IA en la agricultura se agrupan en cuatro dominios: manejo de cultivos, manejo pecuario, manejo del agua y manejo de suelos. Estos sistemas procesan datos de sensores y ofrecen recomendaciones en tiempo real.

Históricamente, el análisis de datos agrícolas se ha apoyado en algoritmos clásicos como las Máquinas de Vectores de Soporte (SVM), los Bosques Aleatorios (Random Forest) y las redes neuronales estándar. Sin embargo, en la actualidad, el aprendizaje profundo ha marcado un punto de inflexión; específicamente, las Redes Neuronales Convolucionales (CNN) se han consolidado como el estándar de la industria gracias a su enorme capacidad para extraer patrones y clasificar imágenes vegetales con alta precisión (Mohanty et al., 2016).

La incorporación de la IA en la agricultura enfrenta retos como la falta de datos y la variabilidad de imágenes. Se construye un modelo CNN ligero para una aplicación móvil accesible.

Aprendizaje automático y aprendizaje profundo

La evolución de las ciencias computacionales ha cambiado cómo los sistemas informáticos resuelven problemas complejos. El enfoque tradicional, que requería un experto humano para definir reglas explícitas, no es suficiente en entornos de alta incertidumbre, como la agricultura. Es aquí donde la inteligencia artificial y sus disciplinas cobran valor, al transformar el análisis de datos agronómicos en un proceso dinámico y adaptable (A. Sharma et al., 2021).

El aprendizaje automático es una subárea de la inteligencia artificial centrada en entrenar modelos matemáticos capaces de aprender a partir de un conjunto de datos. En lugar de seguir instrucciones rígidas, estos algoritmos se alimentan con grandes volúmenes de información en este caso, imágenes etiquetadas de frutos de aguacate para descubrir por sí mismos patrones, correlaciones y reglas de decisión (Liakos et al., 2018). Dentro de este campo, el aprendizaje

supervisado es el más adecuado para el diagnóstico de patologías del fruto: el modelo ajusta de forma iterativa sus parámetros internos según el error entre su predicción y la etiqueta real de la fase de entrenamiento, mejorando así su capacidad de generalización ante datos nuevos (Lecun et al., 2015) y posibilitando los análisis predictivos de enfermedades.

La aplicación del aprendizaje automático clásico en la agricultura se apoyaba en gran medida en algoritmos como las máquinas de vectores de soporte (SVM), los bosques aleatorios (Random Forest) o las redes neuronales artificiales superficiales (Liakos et al., 2018). Aunque estos modelos supusieron un avance frente a las técnicas estadísticas tradicionales, arrastraban un obstáculo: la ingeniería de características. Para que un algoritmo clásico clasificara la imagen de un aguacate como sano o enfermo, un especialista en procesamiento digital de imágenes tenía que diseñar antes los algoritmos que extraían los rasgos relevantes: histogramas de color, descriptores de textura, detección de bordes. Este procedimiento era costoso, dependía en exceso del conocimiento del dominio y resultaba muy frágil ante variaciones naturales del campo, como la iluminación, las sombras o los ángulos de la cámara del dispositivo móvil (Mohanty et al., 2016).

Para superar estas limitaciones, la comunidad científica desarrolló arquitecturas más sofisticadas: el aprendizaje profundo, que emplea redes neuronales con múltiples capas para modelar relaciones complejas en grandes volúmenes de datos, inspirándose en la estructura y el funcionamiento de las redes neuronales biológicas del cerebro humano (Lecun et al., 2015). De este modo, el aprendizaje profundo prescinde de la extracción manual de características mediante un proceso denominado aprendizaje de representaciones. En un modelo de deep learning, la información atraviesa decenas o cientos de capas de neuronas artificiales interconectadas, y el sistema recibe directamente los datos crudos, es decir, la matriz multidimensional de píxeles que compone la fotografía del aguacate (Lecun et al., 2015; Mohanty et al., 2016).

La adopción de la IA en la agricultura también debe sortear retos como la disponibilidad limitada de conjunto de datos, la variabilidad en las condiciones de captura y la exigencia de modelos que operen en dispositivos con recursos limitados o sin conexión a internet; de ahí que se opte por un modelo CNN ligero, entrenado con un conjunto de datos balanceado y desplegable en una aplicación móvil accesible. En sus capas más profundas, la red ensambla la información para representar patrones altamente específicos y abstractos que caracterizan el problema analizado (Lecun et al., 2015) Este desempeño en tareas de clasificación de imágenes, reconocimiento de patrones y análisis visual ha convertido al aprendizaje profundo en una tecnología idónea para diagnosticar enfermedades de los cultivos a partir de imágenes digitales (Goel & Pandey, 1 C.E.; Mohanty et al., 2016).

La expresión visual de patologías como la mancha negra y la roña no es uniforme, ya que varía notablemente según la zona de infección, la madurez del fruto, la variedad genética del aguacate y las condiciones ambientales (Marais, 2004; Mexicana de Fitopatología et al., 2003). Al sustentar el diagnóstico en estas redes profundas se supera la dependencia del análisis visual subjetivo expuesto a la fatiga o a la falta de experiencia del observador y se lo reemplaza por una evaluación objetiva, en la que el estado de salud del fruto se determina mediante un cálculo probabilístico basado en evidencia visual (Mohanty et al., 2016).

Visión artificial en el diagnóstico de enfermedades vegetales

La visión artificial es la rama de la informática que capacita a los sistemas para interpretar y analizar imágenes del mundo real, con el fin de dotar a las máquinas de una percepción semejante o superior a la del ojo humano. Su meta es extraer información de alto nivel de los datos visuales, de modo que las computadoras logren encontrar significado en el contenido y el contexto de las imágenes (Mohanty et al., 2016).

En la agricultura, la visión artificial se emplea para evaluar la salud de los cultivos mediante el análisis visual de hojas, frutos y tallos, lo que potencia la agricultura de precisión (Liakos et al., 2018; R. Sharma et al., 2023) frente a los métodos tradicionales de muestreo manual, lentos y poco eficientes. Esta tecnología habilita un análisis continuo y no destructivo, al convertir el daño biológico en datos digitales que permiten medir la severidad de las infecciones con precisión matemática (Mohanty et al., 2016).

El flujo habitual de trabajo para identificar una enfermedad comienza con la captura de la imagen, cada vez más realizada con la cámara de dispositivos móviles. Dicha imagen se traduce en una matriz de valores numéricos que representan la intensidad lumínica en el espectro RGB (Mohanty et al., 2016). Ahora bien, las condiciones de campo suelen ser imperfectas la luz solar directa y las sombras, por ejemplo, condicionan el resultado, por lo que las técnicas avanzadas de visión computacional y los modelos de aprendizaje profundo resultan útiles para aislar la región de interés (el fruto) del fondo y compensar las variaciones de iluminación (Jiang et al., 2019; Khattak et al., 2021).

La visión artificial ayuda en el diagnóstico de enfermedades del aguacate al reconocer cambios de color que indican hongos.

La colonización por hongos cambia el color del aguacate sano a tonos diferentes (Marais, 2004; Mexicana de Fitopatología et al., 2003). Por ello, la visión artificial puede advertir diferencias sutiles en esas variaciones cromáticas y distinguir, por ejemplo, la clorosis natural de la necrosis celular provocada por Pseudocercospora purpurea, una de las enfermedades objeto de detección (Mexicana de Fitopatología et al., 2003).

Además del color, la visión artificial analiza la geometría, el tamaño, la distribución y la densidad de las anomalías presentes en la epidermis del fruto (Khattak et al., 2021; Syed-Ab-

Rahman et al., 2021). Al medir el diámetro de las lesiones y calcular el área afectada, el algoritmo aporta información útil para determinar la dosificación de agroquímicos requerida (Marais, 2004).

Las texturas irregulares en la superficie del aguacate son otro indicio de ciertas patologías. La visión por computadora cuantifica la textura evaluando la variación de intensidad de los píxeles; así, dado que Sphaceloma perseae genera roña con tejido suberoso y agrietado (Mexicana de Fitopatología et al., 2003), Los algoritmos miden la rugosidad y reconocen patrones de costras para localizar zonas de enfermedad, lo que ayuda a clasificar y evitar confusiones (Matboli & Atia, 2022; Mexicana de Fitopatología et al., 2003). Automatizan el diagnóstico, reduciendo evaluaciones manuales y permitiendo monitoreo en tiempo real mediante aplicaciones móviles (Liakos et al., 2018; R. Sharma et al., 2023).

Redes neuronales convolucionales (CNN)

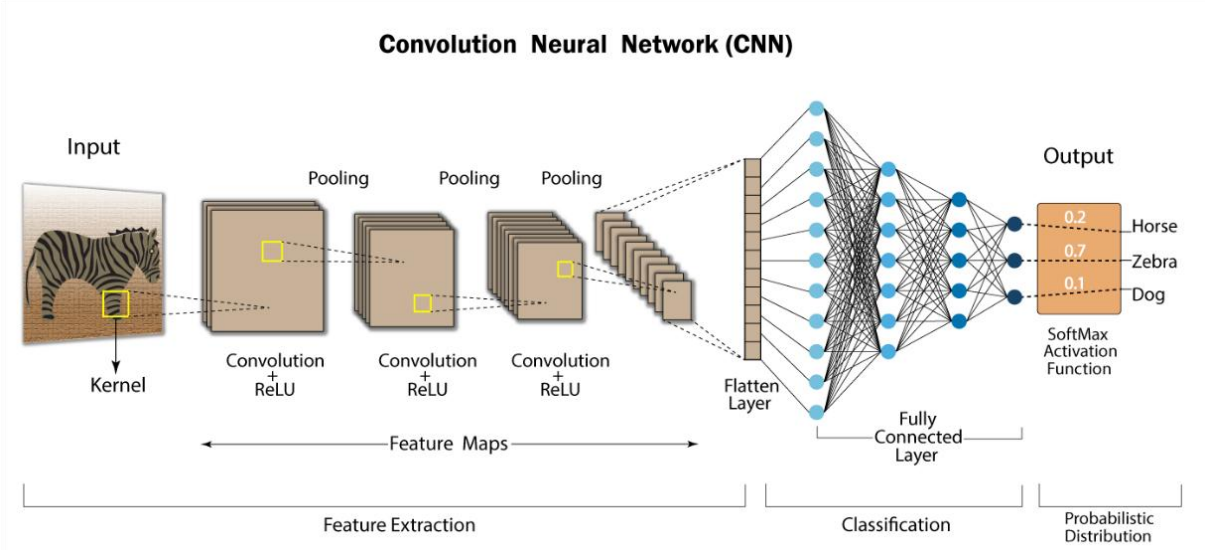
Las redes neuronales convolucionales (CNN) son una arquitectura de aprendizaje profundo concebida para procesar datos con topología de cuadrícula, lo que las hace especialmente adecuadas para el análisis y la clasificación de imágenes digitales (Lecun et al., 2015).

A diferencia de las redes neuronales densas, las CNN incorporan en una de sus capas una operación matemática llamada convolución, que les permite detectar de manera automática patrones espaciales y jerárquicos (Lecun et al., 2015).

Arquitectura y funcionamiento de las CNN

La arquitectura de una CNN se fundamenta en su capacidad de extraer características de lo local a lo global: la información recorre una serie de etapas que transforman los píxeles crudos en conceptos semánticos (Lecun et al., 2015; Mohanty et al., 2016).

Figura 3
Arquitectura de CNN



La **Figura 3** muestra las distintas capas que componen una arquitectura de CNN. El flujo se inicia con la carga de la imagen y continúa en la capa de convolución, donde se aplican múltiples filtros a la imagen de entrada para generar mapas de características que identifican bordes y texturas y, en las capas finales, patrones complejos asociados a las patologías (Lecun et al., 2015).

En la capa de activación o ReLU se aplica la función de unidad lineal rectificada, cuyo propósito es introducir no linealidad en el modelo; de este modo, la red puede aprender representaciones complejas y resolver problemas que no son linealmente separables (Lecun et al., 2015).

La capa de agrupación reduce la dimensionalidad espacial del volumen de datos mediante la técnica de Max-pooling, que extrae el valor máximo de una ventana determinada; con ello se otorga invariancia frente a pequeñas traslaciones y se disminuye el costo computacional (Krizhevsky et al., 2017; Lecun et al., 2015).

Finalmente, en la capa clasificadora o totalmente conectada (fully connected) se aplanan los mapas de características y se conectan a neuronas densas. Esta capa opera como clasificador: emplea la información extraída para asignar la imagen a una categoría específica a través de una función Softmax que devuelve las probabilidades correspondientes.

Aplicación de CNN en clasificación de imágenes

En el ámbito fitosanitario, las CNN permiten automatizar el diagnóstico mediante el reconocimiento de biomarcadores visuales (Goel & Pandey, 1 C.E.; Mohanty et al., 2016); en el caso del aguacate, la red logra diferenciar la textura corchosa de la roña de las lesiones necróticas de la mancha negra (Marais, 2004; Matboli & Atia, 2022; Mexicana de Fitopatología et al., 2003).

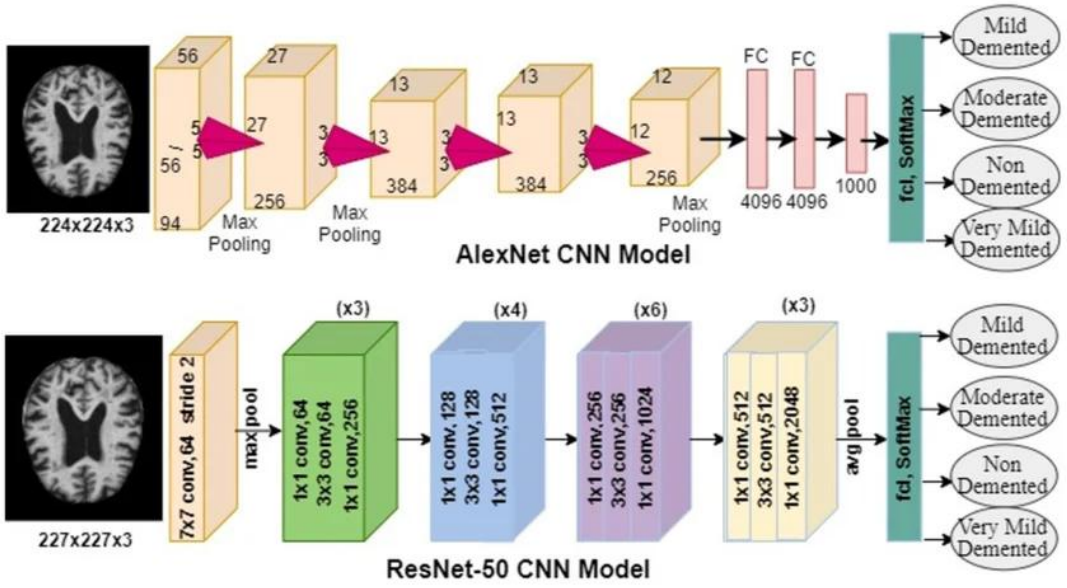
Su principal ventaja es la robustez frente a las variaciones ambientales: mientras los métodos tradicionales fallan ante los cambios de iluminación en el campo, una CNN entrenada con un conjunto de datos balanceado aprende a ignorar el ruido del fondo ramas, cielo o suelo y a concentrarse exclusivamente en las anomalías de la epidermis del aguacate (Jiang et al., 2019; Khattak et al., 2021; Xu & Wang, 2023; Zhu et al., 2023).

Modelos de CNN para clasificación de imágenes

Modelos CNN tradicionales

Los modelos tradicionales sentaron las bases del estado del arte actual, orientándose a maximizar la precisión sobre grandes volúmenes de datos (Goel & Pandey, 1 C.E.). De ellos destacan dos arquitecturas relevantes, que se aprecian en la **Figura 4**.

Figura 4
Arquitectura AlexNet y ResNet-50



AlexNet transformó la visión por computadora al emplear capas convolucionales profundas y técnicas de regularización como el dropout para manejar millones de parámetros (Krizhevsky et al., 2017). Este modelo probó que las redes profundas podían superar de manera notable a los métodos tradicionales en las tareas de clasificación de imágenes.

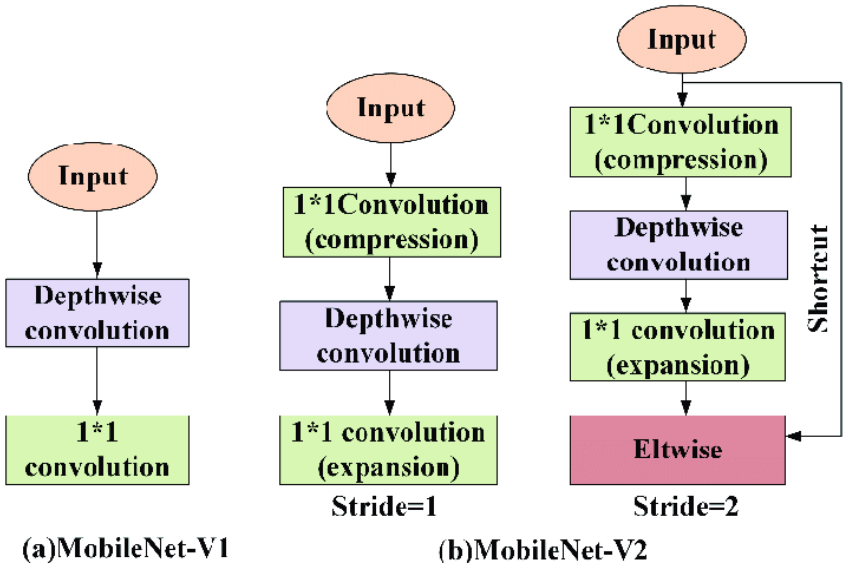
Por su parte, ResNet incorporó bloques residuales que hicieron posible entrenar redes extremadamente profundas de alrededor de 100 capas mediante conexiones de salto (skip connections) (Mohanty et al., 2016). Con ello resolvió el problema de la degradación del gradiente y habilitó la captura de detalles finos en las imágenes de los frutos (Goel & Pandey, 1 C.E.; Mohanty et al., 2016).

Modelos CNN eficientes para dispositivos móviles

Para aplicaciones como Avocado IA, que exigen ejecución local sin depender de servidores, se han desarrollado arquitecturas optimizadas para hardware con recursos restringidos (Howard et al., 2017; Sandler et al., 2018; Tan & Le, 2019).

Figura 5

Arquitectura de MobileNet-V1 y MobileNet-V2



La **Figura 5** presenta el bloque básico de MobileNet-V1, que incluye una capa depthwise donde esta es encargada de aplicar un único filtro por cada canal de entrada para procesar la parte espacial, como bordes o formas y una capa de convolución que combina esos resultados en un nuevo espacio de canales. Mezcla información de canales y reduce costos computacionales. (Howard et al., 2017)

MobileNet-V2 mejora la arquitectura con bloques residuales invertidos (Sandler et al., 2018). Aunque la imagen muestra compresión y expansión, la arquitectura funciona al revés para retener información, y su flujo se bifurca en el procesamiento de datos.

El primer flujo se activa cuando se busca procesar los detalles de la imagen conservando su tamaño original, a través del bloque inicial de extracción de características.

El segundo flujo interviene cuando es necesario resumir la información o reducir las dimensiones; al disminuir el tamaño de la imagen, la red se concentra en los rasgos generales y aminora el costo computacional.

Por último, la arquitectura EfficientNet aplica un método de escalado compuesto que equilibra de forma óptima la profundidad, el ancho y la resolución de la red, logrando eficiencia y resultados de vanguardia con una fracción de los parámetros de los modelos tradicionales (Tan & Le, 2019).

La siguiente tabla ofrece una comparación técnica que respalda la elección del modelo.

Tabla 2
Comparativa de arquitecturas CNN.

Modelo	**Parámetros (aprox.)**	**Operaciones (MADDs)**	**Ventaja Clave**	**Uso Recomendado**
AlexNet	60 millones	720 millones	Robustez histórica	Estación de trabajo
ResNet-50	25 millones	3.8 billones	Alta precisión	Servidor / Cloud
MobileNetV2	3.4 millones	300 millones	Baja latencia móvil	App Móvil Offline
EfficientNet-B0	5.3 millones	390 millones	Eficiencia óptima	App Móvil de alta gama

Nota: *MADDs indica multiplicaciones y adiciones (Multiply-Accumulate Operations). El tamaño y consumo de memoria RAM de MobileNetV2 lo fundamentan como la arquitectura idónea para el enfoque offline-first de la aplicación móvil.*

Aplicaciones móviles en el sector agrícola y brecha digital

La integración de las tecnologías de la información y la comunicación en el campo, conocida como agricultura inteligente, ha transformado la gestión de los cultivos al llevar el procesamiento de datos desde los laboratorios hasta el productor (Liakos et al., 2018; A. Sharma et al., 2021). Sin embargo, implementar software complejo como los modelos de aprendizaje profundo choca con la brecha técnica y digital del entorno rural.

En regiones agrícolas como el cantón Sigchos, la red suele ser deficiente o inexistente. Esto hace que los sistemas de inteligencia artificial tradicionales, que operan en la nube, dependan de una conexión que ahí no existe, lo que los vuelve inviables para el monitoreo en tiempo real.

Se propone una arquitectura offline-first, donde el modelo se ejecuta nativamente en el dispositivo móvil sin internet.

El despliegue de CNN en dispositivos móviles debe contemplar la heterogeneidad del hardware, pues los agricultores suelen contar con terminales de gama media (Howard et al., 2017; Sandler et al., 2018). Por ello, arquitecturas como MobileNet se han diseñado específicamente para funcionar de manera eficiente en dispositivos con recursos computacionales limitados (Howard et al., 2017; Sandler et al., 2018; Tan & Le, 2019)

Capítulo III

Metodología

Enfoque de la investigación

El presente trabajo de titulación adopta un enfoque mixto de predominancia cuantitativa, orientado a la recolección, medición y análisis numérico de datos. Su finalidad es comprobar el desempeño de un modelo de aprendizaje profundo en la detección de patologías del aguacate a partir de variables medibles, como la precisión, la exhaustividad y la exactitud de clasificación de la red neuronal convolucional.

Tipo y alcance de la investigación

La investigación utiliza aprendizaje profundo y visión por computadora para detectar tempranamente mancha negra y roña en aguacates, así como identificar frutos sanos. El estudio es descriptivo al caracterizar enfermedades, correlacional al vincular imágenes con patologías, y experimental, al diseñar, entrenar y evaluar un modelo de red neuronal convolucional optimizando variables. (Mohanty et al., 2016)

Diseño metodológico

El diseño metodológico se organiza en ocho fases que garantizan la trazabilidad y la reproducibilidad en la construcción del modelo convolucional utilizado en la aplicación móvil para la detección de anomalías en el aguacate, según se detalla en la Tabla 3.

Tabla 3
Fases del diseño metodológico para la construcción del modelo.

Fase	Actividad	Detalle
1. Captura de imágenes	Fotografía de frutos en una finca de Sigchos y descarga de repositorios públicos	2999 imágenes
2. Etiquetado	Asignación de cada imagen a una de las tres clases	mancha negra, roña, sana
3. Validación	Revisión de la clasificación por un experto	Ing. Guido Sigcha
4. Preprocesamiento	Redimensionamiento y normalización	224 × 224 px; RGB [0, 1]
5. Aumento de datos	Transformaciones sobre el conjunto de entrenamiento	rotación, desplazamiento, zoom, volteo y brillo
6. División del conjunto	Partición estratificada con semilla fija (42)	2099 / 449 / 451 (70/15/15 %)
7. Entrenamiento	Aprendizaje por transferencia con MobileNetV2	30 épocas + fine-tuning
8. Evaluación	Cálculo de métricas sobre el conjunto de prueba	precisión, recall, F1 y exactitud

Población y muestra

La población de estudio estuvo conformada por hojas y frutos de aguacate (Persea americana) procedentes de Sigchos, Cotopaxi, con el propósito de investigar sus enfermedades. En total se analizaron 2999 imágenes (1000 de mancha negra, 1000 de roña y 999 de frutos sanos), distribuidas en subconjuntos de entrenamiento, validación y prueba para su análisis.

Recolección de datos

La recolección de datos comenzó con la generación de imágenes que documentan las condiciones del cultivo de aguacate, en un proceso de captura y validación.

Construcción del conjunto de datos de imágenes

La construcción del conjunto de imágenes se apoyó en fotografías tomadas con un teléfono móvil en una finca de aguacate de Sigchos, Cotopaxi, así como en imágenes procedentes de repositorios públicos. El material se organizado en tres clases mancha negra, roña y sana.

Como se puede ver en la Tabla 8 resume la estructura del conjunto por cada clase mencionada.

Etiquetado y validación de imágenes

Tras reunir el conjunto de imágenes, cada una se organizó en una de tres categorías según la clase que representaba: mancha negra, roña o sana. Esta clasificación fue revisada y validada por el Ing. Guido Sigcha, quien verificó la correcta asignación de cada imagen a su categoría.

Figura 6

Construcción y validación de la clasificación de las imágenes con el Ing. Guido Sigcha.



Preprocesamiento de datos

Antes de emplearse en el entrenamiento del modelo, las imágenes se preprocesaron con TensorFlow para estandarizar su formato y mejorar la capacidad de generalización.

Normalización y aumento de datos

Todas las imágenes se redimensionaron a 224 × 224 píxeles y sus valores de intensidad se normalizaron dividiendo cada píxel entre 255, lo que favorece la estabilidad y la velocidad de convergencia durante el entrenamiento. Para ampliar la variabilidad del conjunto de entrenamiento y reducir el sobreajuste, se aumentaron los datos con transformaciones sobre las imágenes de entrenamiento: rotaciones de hasta 45 grados, desplazamientos del 20 %, recorte y zoom del 20 %, volteos horizontales y verticales, y cambios de brillo entre 0,8 y 1,2. Con esto el modelo detecta las condiciones en las que se encuentran como por ejemplo las hojas bajo condiciones de luz y encuadre distintas, ya que son las que se dan en campo.

División de datos (entrenamiento, validación y prueba)

Para la clasificación de las imágenes se realizó por 3 grupos siendo entrenamiento, validación y pruebas para evaluar el modelo, por lo tanto, las cifras para cada subconjunto fueron 2099 imágenes para entramiento, 449 para validación y 451 para prueba, teniendo una partición fija de modo que se puede reproducir como es. La **Tabla 8** muestra la distribución de imágenes en cada subconjunto.

Entrenamiento del modelo CNN

Para el entrenamiento se empleó una estrategia de aprendizaje por transferencia, adecuada para reutilizar una red base MobileNetV2 preentrenada con el conjunto de datos ImageNet. Esta arquitectura se eligió por su eficiencia computacional y su reducido número de parámetros, cualidades que la hacen idónea para el posterior despliegue en dispositivos móviles. Las capas convolucionales de la red base se mantuvieron congeladas, con el fin de conservar los patrones visuales aprendidos previamente, y sobre ellas se añadió un clasificador personalizado.

El clasificador está compuesto por una capa de agrupamiento promedio global, capas densas de 512 y 256 neuronas con activación ReLU, normalización por lotes y capas de abandono (dropout) de 0,3 a 0,5. La capa de salida cuenta con tres neuronas y activación softmax, correspondientes a las clases mancha negra, roña y sana.

El modelo se compiló con el optimizador Adam y la función de pérdida de entropía cruzada categórica, apropiada para los problemas de clasificación de clases, tanto de enfermedades como de frutos sanos. Las imágenes se procesaron en lotes de 32, con una tasa de aprendizaje inicial de 0,0001 y 30 épocas de entrenamiento. Durante todo el proceso se monitorearon las métricas de exactitud, precisión, exhaustividad y valor F1; la **Tabla 11** resume los principales hiperparámetros del entrenamiento.

Con el objetivo de optimizar el entrenamiento y evitar el sobreajuste se implementaron varios callbacks: la parada temprana (early stopping), la reducción adaptativa de la tasa de aprendizaje ante el estancamiento y el guardado del mejor modelo según el desempeño en validación.

El entrenamiento se organizó en dos fases:

1. En la primera, con la base de MobileNetV2 congelada, se completaron las 30 épocas previstas y el mejor valor de exactitud en validación (0,9644) se alcanzó en la época 24.
2. En la segunda fase se aplicó fine-tuning dodne se descongeló la base a partir de la capa 100 y se reentrenó durante diez épocas adicionales (de la 31 a la 40) con una tasa de aprendizaje de 1×10^{-5}, esta fase se detuvo por parada temprana en la época 40 dando como resultado que no supero el desempeño de validación de la fase congelada. En consecuencia, el modelo final corresponde a los pesos de la época 24.

Técnicas de evaluación y métricas

Para validar el desempeño del modelo se emplearon métricas propias de los problemas de clasificación, calculadas sobre el conjunto de prueba. Estas métricas se derivan de los conceptos de verdaderos positivos, verdaderos negativos, falsos positivos y falsos negativos, que permiten analizar el comportamiento del modelo tanto de manera global como específica.

Las métricas consideradas fueron la precisión, la exhaustividad (recall) y el valor F1 (F1-score), complementadas con la exactitud global. En la fase de prueba, el modelo alcanzó una exactitud global del 96,22 %, con una precisión, una exhaustividad y un valor F1 macro promedio del 96,23 %, el 96,23 % y el 96,22 %, respectivamente, cifras que evidencian un desempeño satisfactorio en la tarea de clasificación.

Precisión

La precisión mide qué proporción de las predicciones positivas fue correcta: de todas las imágenes que el modelo asignó a una clase, cuántas pertenecen realmente a ella. Se calcula como el cociente entre los verdaderos positivos y la suma de verdaderos positivos y falsos positivos. En el conjunto de prueba el modelo alcanzó una precisión promedio del 96,23 %. Ninguna clase bajó del 94 %: sana 98,03 %, mancha negra 95,89 % y roña 94,77 %. Este equilibrio se explica por el uso de un conjunto de datos balanceado.

Recall

La exhaustividad o conocida como recall evalúa la capacidad del modelo para identificar correctamente todas las muestras de datos que realmente pertenecen a una clase (roña, macha negra y sano) en otras palabras, de todas las imágenes que corresponden a una categoría, indica cuántas fueron detectadas correctamente.

Para calcula como el cociente entre los verdaderos positivos y la suma de verdaderos positivos y falsos negativos, según la expresión $Recall = \frac{VP}{(VP + FN)}$. Sobre el conjunto de prueba, el modelo obtuvo una exhaustividad promedio del 96,23 %, con valores de 0,93 en mancha negra, 0,97 en roña y 0,99 en sana, lo que refleja una alta sensibilidad para reconocer las tres categorías.

F1-score

El valor F1 representa la media armónica entre la precisión y la exhaustividad y ofrece una medida equilibrada del desempeño cuando ambas métricas resultan igual de importantes; por ello es especialmente útil en conjuntos desbalanceados, ya que penaliza los casos en que existe una diferencia marcada entre precisión y recall. En la parte de evaluación, el conjunto de aguacates sanos obtuvo un valor de 0.98 mientras que la enfermedad de la mancha negra un 0.95, teniendo un prometido marco de F1 de 0.96 y un promedio ponderado de 0.96, confirmando así que el desempeño global es sólido y equilibrado en las 3 categorías.

Capítulo IV

Desarrollo del sistema propuesto

Análisis de requerimientos

Para el análisis de requerimientos es una etapa del ciclo de vida del software para el proyecto de Avocado IA, se tuvo entrevistas con agricultores de aguacate y partes interesadas en el proyecto.

Requerimientos Funcionales

Los requerimientos funcionales describen las capacidades concretas que el sistema debe ofrecer a sus usuarios. A continuación, se presentan los requerimientos funcionales identificados para la aplicación Avocado IA:

Tabla 4

Requerimientos funcionales del sistema Avocado IA.

ID	Requerimiento	Descripción	Prioridad
RF-01	Captura de imagen	El sistema debe permitir al usuario tomar fotografías del aguacate directamente desde la cámara del móvil o seleccionar imágenes desde galería.	**Alta**
RF-02	Detección de enfermedades	El sistema debe analizar la imagen y clasificar el fruto entre las tres categorías: Sano, Mancha Negra o Roña, utilizando el modelo.	**Alta**
RF-03	Nivel de confianza	El sistema debe mostrar el porcentaje de la predicción realizada por el modelo de IA.	**Alta**
RF-04	Recomendaciones fitosanitarias	El sistema debe dar recomendaciones de tratamiento agrícola tradicionale según el tipo de enfermedad detectada.	**Alta**
RF-05	Historial de detecciones	El sistema debe tener un historial persistente de todas las detecciones realizadas.	**Media**
RF-06	Panel de estadísticas (Dashboard)	El sistema debe mostrar estadísticas visuales de las detecciones acumuladas.	**Media**
RF-07	Calculadora de incidencia	El sistema debe calcular la incidencia de enfermedades en un lote.	**Media**
RF-08	Soporte multi idioma	El sistema debe tener interfaz en español e inglés.	**Baja**
RF-09	Modo sin conexión	El sistema debe operar sin internet (offline), ejecutando el modelo localmente en el dispositivo.	**Alta**

RF-10	Gestión de espacios de trabajo	El sistema debe permitir organizar las detecciones en espacios de trabajo independientes para distintos lotes.	**Baja**

Nota. Elaboración propia.

Requerimientos No Funcionales

Los requerimientos no funcionales definen limitaciones y atributos que deberían tener el entorno para la calidad del sistema de Avocado IA ya que debe satisfacer al usuario en usabilidad, rendimiento y confiabilidad.

Tabla 5
Requerimientos no funcionales del sistema Avocado IA.

Categoría	Requerimiento	Criterio de Aceptación
Rendimiento	Tiempo de respuesta de la inferencia	El proceso de análisis de imagen debe completarse en menos de 3 segundos en dispositivos con al menos 2 GB de RAM.
Portabilidad	Compatibilidad con sistemas operativos	La aplicación debe ser compatible con Android 6.0 o superior e iOS 12.0 o superior.
Usabilidad	Interfaz intuitiva	El usuario debe completar el flujo normal del sistema en menos de 1 minuto.
Disponibilidad	Funcionamiento offline	El modelo de inferencia debe correr en el dispositivo teniendo o no internet.
Tamaño del modelo	Archivo. tflite optimizado	El modelo TensorFlow Lite no debe superar 5 MB.
Mantenibilidad	Arquitectura modular	El código fuente debe seguir el patrón de arquitectura que es por características para ser escalable y mantenible.
Seguridad	Privacidad de datos	Las imágenes y resultados de detección deben almacenarse únicamente de forma.

Escalabilidad	Actualización del modelo	La arquitectura debe permitir la sustitución del modelo. tflite.

Nota. Elaboración propia.

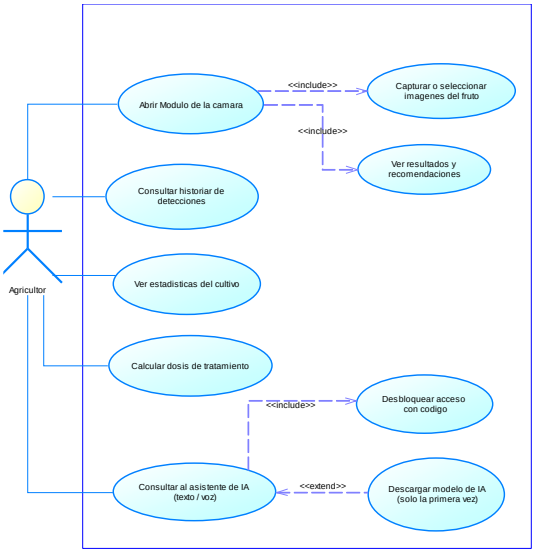
Diagrama de casos de uso

El diagrama de casos de uso describe las funcionalidades del sistema Avocado IA desde la perspectiva de su actor principal, el agricultor, quien interactúa con la aplicación para diagnosticar el estado fitosanitario de sus frutos. A partir de los requerimientos funcionales definidos, se identificaron los siguientes casos de uso: capturar o seleccionar una imagen del fruto, ejecutar el diagnóstico mediante el modelo de clasificación, visualizar el resultado con su nivel de confianza y las recomendaciones asociadas, registrar y consultar el historial de análisis, revisar el panel de estadísticas, calcular la incidencia de enfermedades por lote y configurar el idioma de la aplicación.

El caso de uso central, Diagnosticar enfermedad, incluye la captura y el preprocesamiento de la imagen, y deriva en la presentación de resultados y su registro en el historial local. Al ejecutarse por completo en el dispositivo, todos los casos de uso operan sin conexión a internet. La **Figura 7** presenta el de casos de uso del sistema.

Figura 7

Diagrama de casos de uso del sistema Avocado IA.



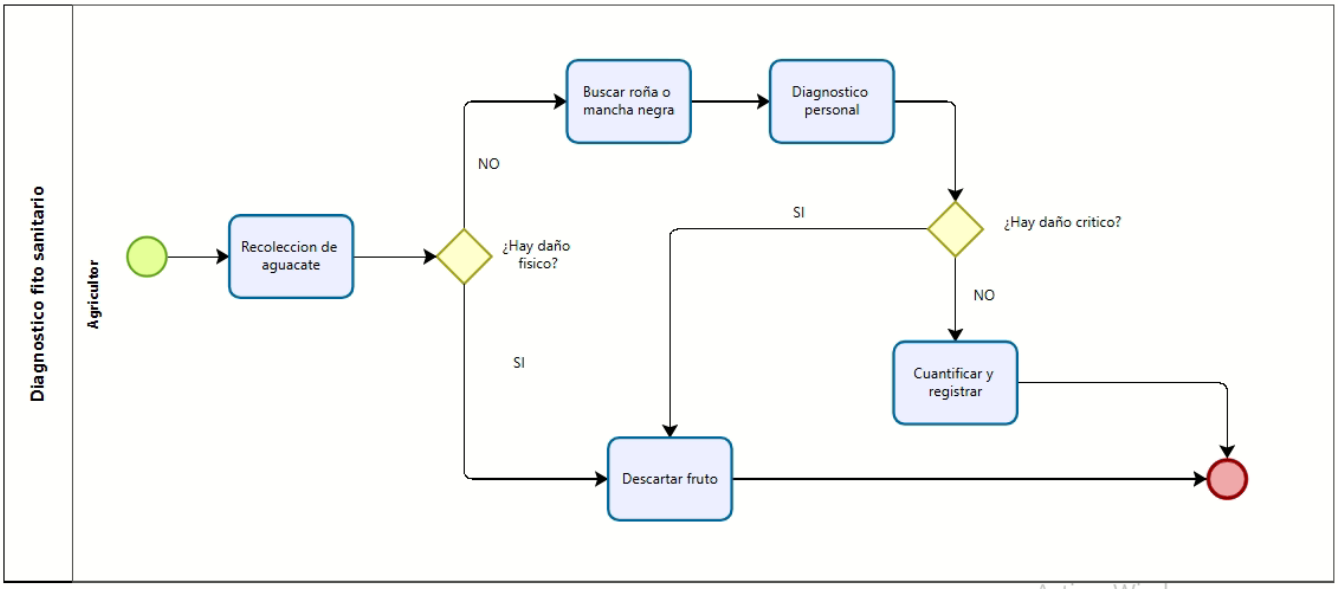
Modelo de procesos de negocio

El modelo de procesos de negocio representa el flujo de trabajo que sigue el agricultor para obtener un diagnóstico fitosanitario, contrastando el proceso tradicional basado en la inspección visual manual con el proceso automatizado que propone Avocado IA. El proceso inicia cuando un usuario o agricultor detecta un fruto de aguacate sospechoso ya sea por cualquier daño o enfermedad, y captura con su teléfono la imagen desde la aplicación, pero también tiene la opción de cargar la imagen, la cual es procesa y enviada al modelo de clasificación.

El sistema a el resultado de la predicción de la categoría a la que pertenece el fruto junto con un nivel de confianza, con una recomendación fitosanitaria, el cual el resultado se almacena en el positivo localmente y de manera opcional se puede alimentar el cálculo de incidencia de enfermedades por lote. Este flujo, ejecutado íntegramente en el dispositivo y sin conexión, reduce el tiempo de diagnóstico y elimina la dependencia de un experto en campo. La **Figura 8** ilustra el diagrama de procesos de negocio del sistema.

Figura 8

Diagrama de procesos de negocio del diagnóstico fitosanitario con Avocado IA.

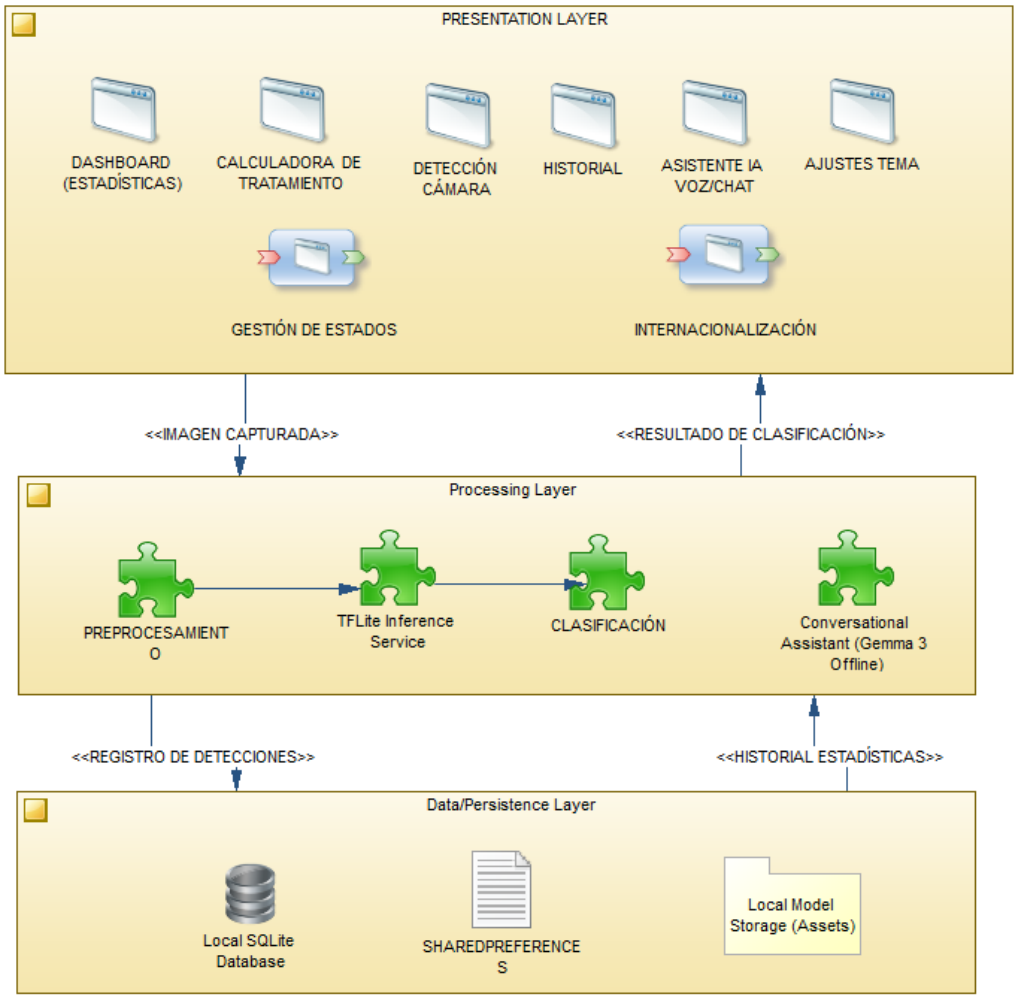


Diseño de la arquitectura del sistema

La arquitectura del sistema Avocado IA tiene tres capas: el frontend móvil en Flutter, la lógica de procesamiento local con TensorFlow Lite y la capa de persistencia con SQLite usando sqflite. Esto permite funcionar sin servicios en la nube, importante para zonas rurales con poca conectividad.

Figura 9

Diagrama general de la arquitectura del sistema Avocado IA.



La arquitectura del sistema Avocado IA se estructura en tres capas: un frontend móvil desarrollado en Flutter, una capa de procesamiento local basada en TensorFlow Lite y una capa de persistencia implementada con SQLite mediante sqflite. Este diseño permite que la aplicación funcione sin depender de servicios en la nube, aspecto clave para las zonas rurales con conectividad limitada.

Capa de Lógica de Negocio (Business Logic Layer):

Emplea el patrón provider aplicado en los módulos detection, locale y connectivity para administrar el estado de la aplicación y coordinar las operaciones entre los datos y la interfaz de usuario.

Capa de Datos (Data Layer): integrada por la base de datos local SQLite, gestionada por DatabaseHelper, y por el modelo entrenado avocaddoModel almacenado en la propia aplicación; la base de datos se encarga de mantener las tablas de espacios de trabajo y de resultados de detección.

Tabla 6

Organización modular del código fuente por características.

Módulo	Ruta en el proyecto	Responsabilidad
Core	lib/core/	Constantes, modelos de datos, providers globales y capa de base de datos
Detection	lib/features/detection/	Lógica de captura de imagen, inferencia del modelo y persistencia del resultado
Dashboard	lib/features/dashboard/	Visualización de estadísticas y actividad reciente
Calculator	lib/features/calculator/	Cálculo de incidencia de enfermedades por lote de frutos
Main	lib/features/main/	Navegación principal y página de configuración
Localización	lib/l10n/	Archivos de internacionalización para ES e EN

Nota. Elaboración propia. La estructura del código fuente en Flutter sigue el patrón de organización por características (feature-first), que agrupa los archivos según su funcionalidad de negocio y no según su tipo técnico. Esta decisión de diseño favorece la escalabilidad y el mantenimiento independiente de cada módulo.

Esquema de la Base de Datos Local

La persistencia de datos se implementa con SQLite a través del paquete sqflite. La base de datos contiene dos tablas relacionales que almacenan los resultados de detección y los espacios de trabajo del usuario.

Tabla 7
Esquema de la base de datos local SQLite del sistema Avocado IA.

Tabla	Campo	Tipo	Descripción
workspaces	id	TEXT PK	Identificador único del espacio de trabajo
workspaces	name	TEXT	Nombre del espacio de trabajo
workspaces	description	TEXT	Descripción opcional
workspaces	createdAt	TEXT	Fecha de creación (ISO 8601)
workspaces	isActive	INTEGER	Estado activo (1) o inactivo (0)
detection_results	id	INTEGER PK	Identificador autoincremental
detection_results	diseaseType	TEXT	Tipo detectado: healthy, mancha_negra, rona
detection_results	confidence	REAL	Nivel de confianza.
detection_results	imagePath	TEXT	Ruta de la imagen analizada de manera local
detection_results	timestamp	TEXT	Fecha y hora de la detección
detection_results	workspaceId	TEXT FK	Referencia al workspace asociado
detection_results	notes	TEXT	Notas por parte del usuario

Nota. Elaboración propia.

Diseño de la arquitectura del modelo CNN

El modelo de aprendizaje profundo de Avocado IA se construyó mediante Transfer Learning sobre MobileNetV2, preentrenada en ImageNet, combinación que ofrece una alta

precisión con un tamaño reducido (3.2 MB en formato TFLite), idóneo para su ejecución en dispositivos móviles.

Descripción del Conjunto de datos

El conjunto de datos empleado en el entrenamiento se recolectó y etiquetó de forma manual, y reúne imágenes de frutos de aguacate agrupadas en tres categorías: Mancha Negra (mancha_negra), Roña (ronia) y Sano (sana). Su distribución se detalla en la **Tabla 8**.

Tabla 8
Distribución del conjunto de datos de imágenes por clase y partición.

Partición	Mancha Negra	Roña	Sana	Total
Entrenamiento	700	700	699	2099
Validación	150	150	149	449
Test	150	150	151	451
Total	1000	1000	999	2999

Nota. Elaboración propia.

El preprocesamiento de las imágenes comprendió su redimensionamiento a 224×224 píxeles y la normalización de los valores RGB al rango [0.0, 1.0]. Sobre el conjunto de entrenamiento se aplicaron, además, técnicas de aumento de datos (data augmentation) para enriquecer la diversidad del conjunto de datos y potenciar la capacidad de generalización del modelo.

Tabla 9
Técnicas de aumento de datos aplicadas al conjunto de entrenamiento.

Técnica de Augmentation	Parámetro	Valor
Rotación aleatoria	rotation_range	45°
Desplazamiento horizontal	width_shift_range	20 %
Desplazamiento vertical	height_shift_range	20 %
Corte (shear)	shear_range	20 %
Zoom aleatorio	zoom_range	20 %
Volteo horizontal	horizontal_flip	Activado
Volteo vertical	vertical_flip	Activado
Ajuste de brillo	brightness_range	[0.8 – 1.2]

Nota. Elaboración propia.

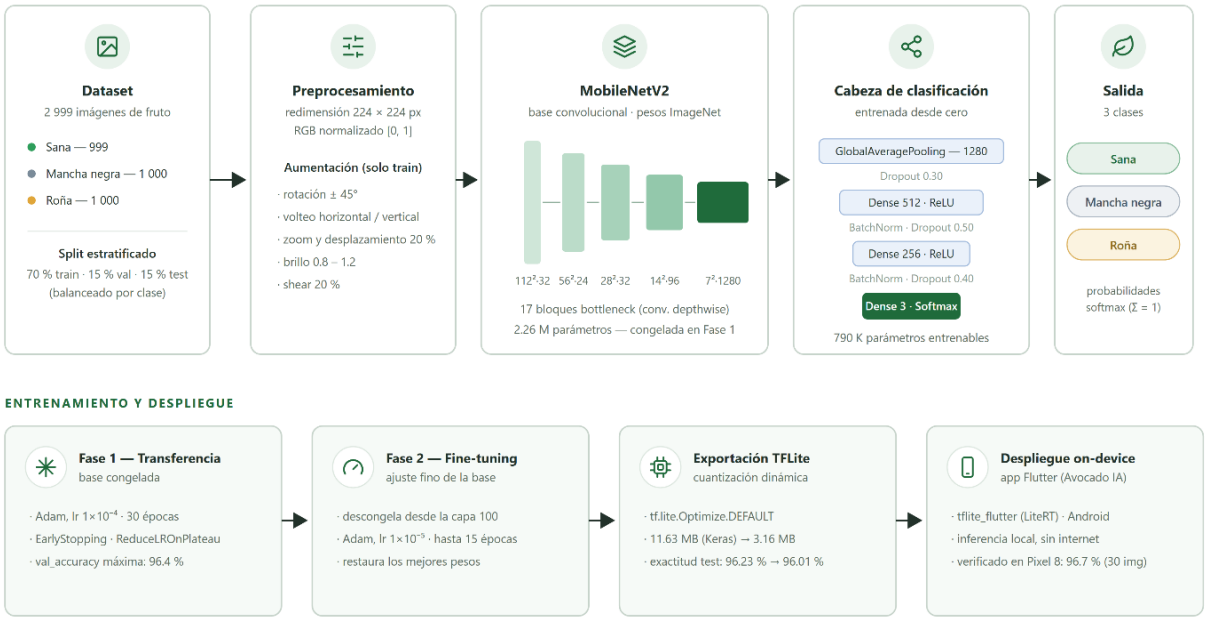
Arquitectura MobileNetV2 con Transfer Learning

MobileNetV2 es una arquitectura de red neuronal convolucional concebida específicamente para dispositivos con recursos limitados. Al basarse en bloques de cuello de botella invertido con convoluciones separables en profundidad, reduce de forma considerable el número de parámetros frente a arquitecturas clásicas como VGG o ResNet.

La estrategia de Transfer Learning adoptada consiste en congelar los pesos del modelo base previamente entrenado con ImageNet y añadir capas densas personalizadas para clasificar las dos enfermedades, roña y mancha negra, junto con una categoría de frutos sanos. Como segunda fase se aplicó Fine-Tuning, descongelando la base a partir de la capa 100 y reentrenando durante diez épocas con una tasa de aprendizaje reducida (1×10^{-5}); no obstante, esta fase no superó el desempeño en validación logrado con la base congelada, por lo que el modelo final conservó los pesos de la fase congelada.

Figura 10

Arquitectura del modelo de clasificación basado en MobileNetV2 con transfer learning.



Nota. Elaboración propia.

Tabla 10

Arquitectura detallada del modelo CNN Avocado IA.

Capa	Tipo	Forma de Salida	Parámetros
1	MobileNetV2 (base congelada)	(None, 7, 7, 1280)	2,257,984 (no entrenables)
2	GlobalAveragePooling2D	(None, 1280)	0
3	Dropout (rate=0.3)	(None, 1280)	0
4	Dense (512, ReLU)	(None, 512)	655,872
5	BatchNormalization	(None, 512)	2,048
6	Dropout (rate=0.5)	(None, 512)	0
7	Dense (256, ReLU)	(None, 256)	131,328
8	BatchNormalization	(None, 256)	1,024
9	Dropout (rate=0.4)	(None, 256)	0
10	Dense (3, Softmax)	(None, 3)	771
	TOTAL		3,049,027 (789,507 entrenables)

Nota. Elaboración propia.

Configuración de Hiperparámetros de Entrenamiento

Tabla 11

Hiperparámetros de configuración del entrenamiento del modelo CNN.

Hiperparámetro	Valor	Justificación
Tamaño de imagen de entrada	224 × 224 × 3 píxeles	Resolución estándar de MobileNetV2 preentrenada con ImageNet
Tamaño de lote (batch size)	32 imágenes	Balance entre velocidad de convergencia y uso de memoria GPU
Épocas (fase base congelada)	30	Se completaron; el mejor modelo de validación se obtuvo en la época 24
Fine-tuning (2.ª fase)	Descongelado desde la capa 100; 10 épocas (31–40); lr 1×10^{-5}	No superó el desempeño de validación de la fase congelada; parada temprana en la época 40
Tasa de aprendizaje inicial	1×10^{-4} (Adam)	Valor conservador para Transfer Learning con capas congeladas
Función de pérdida	Categorical Crossentropy	Apropiada para clasificación multiclase con salida softmax
Número de clases	3	Mancha Negra, Roña y Sana
Semilla de reproducibilidad	42	Garantiza resultados reproducibles entre ejecuciones

Nota. Elaboración propia.

Resultados del Entrenamiento y Evaluación

El modelo se evaluó sobre el conjunto de prueba, integrado por 451 imágenes totalmente independientes de las usadas en el entrenamiento y la validación. Los resultados alcanzados confirman la viabilidad de la arquitectura propuesta para el diagnóstico fitosanitario del aguacate.

Tabla 12

Métricas de evaluación del modelo CNN en el conjunto de test.

Métrica	Mancha Negra	Roña	Sana	Promedio Ponderado
Precisión (Precision)	95.89 %	94.77 %	98.03 %	96.23 %
Exhaustividad (Recall)	93.33 %	96.67 %	98.68 %	96.23 %
F1-Score	94.59 %	95.71 %	98.35 %	96.22 %
Exactitud global (Accuracy)	—	—	—	96.23 %

Nota. Elaboración propia.

Los datos obtenidos reflejan una exactitud global del 96.23 % y un valor F1 macro del 96.22 %, lo que revela un desempeño equilibrado entre las tres clases. La categoría mejor reconocida fue el fruto sano, con un F1 del 98.35 %, mientras que la mancha negra y la roña alcanzaron un F1 del 94.59 % y el 95.71 %, respectivamente; los escasos errores de clasificación se concentran entre estas dos patologías, que comparten el aspecto de lesión oscura sobre la epidermis del fruto.

Conversión y Optimización a TensorFlow Lite

Tras validar el modelo en el entorno de entrenamiento (Google Colab con GPU T4), se procedió a convertirlo al formato TensorFlow Lite (.tflite), optimizado para la inferencia en dispositivos móviles de recursos limitados. La conversión utilizó la optimización DEFAULT de TFLite, que aplica cuantización dinámica de pesos y redujo el tamaño del modelo de 18 MB (formato Keras .h5) a 3.2 MB (.tflite), es decir, una disminución del 82 % sin una pérdida significativa de exactitud.

Tabla 13

Comparación entre el modelo Keras original y el modelo TensorFlow Lite.

Característica	**Modelo Keras (.h5)**	**Modelo TFLite (.tflite)**
Tamaño en disco	18MB	3.2 MB
Framework de inferencia	TensorFlow / Keras	TensorFlow Lite Interpreter
Plataforma objetivo	Servidor / GPU	Android / iOS / Embedded
Optimización aplicada	Ninguna	Cuantización dinámica de pesos (DEFAULT)
Forma tensor de entrada	[None, 224, 224, 3]	[1, 224, 224, 3] float32
Forma tensor de salida	[None, 3]	[1, 3] float32
Reducción de tamaño	—	82 % menos respecto al modelo Keras

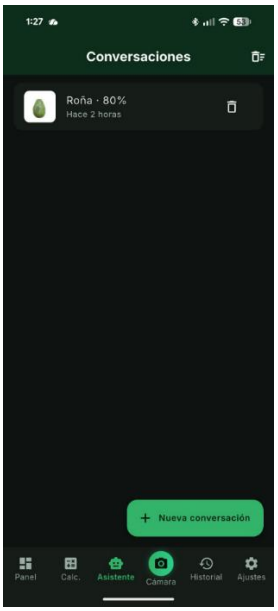
Nota. Elaboración propia.

Componentes de la aplicación móvil

La aplicación Avocado IA se desarrolla con Flutter, de Google, lo que permite generar binarios nativos para Android e iOS a partir de una única base de código en Dart. Su interfaz se ajusta a Material Design 3 y se organiza mediante un BottomNavigationBar de seis elementos.

Figura 11

Vista general de la navegación principal de Avocado IA con los seis módulos.



Módulo de Captura de Imágenes

El módulo de captura de imágenes se corresponde con la pantalla Cámara (CameraPage) y representa el punto de entrada del flujo de diagnóstico. A través de él, el usuario obtiene la imagen del fruto de aguacate que desea analizar por dos vías alternativas:

- Cámara del dispositivo: activa la cámara nativa del teléfono mediante el paquete image_picker, lo que permite tomar la fotografía directamente en la aplicación con una resolución máxima de 1920×1080 píxeles y una calidad del 85 %.
- Galería de fotos: permite seleccionar una imagen tomada con anterioridad desde el almacenamiento del dispositivo, esta opción es útil cuando el usuario desea analizar fotografías tomadas previamente.

Una vez elegida la imagen, se muestra una vista previa de 400 píxeles de alto dentro del dispositiva, al pulsar “Analizar”, la imagen se redimensiona a 224×224 px y se envía al modelo, mientras se despliega un indicador de progreso. Los resultados se presentan en una tarjeta y quedan registrados en el historial.

Figura 12

Módulo de captura de imágenes: selección desde cámara/galería y vista previa.



Módulo de Clasificación de Enfermedades

El módulo de clasificación es el núcleo inteligente del sistema y se implementa en la clase DetectionService, que concentra la lógica de inferencia del modelo ejecutándola de forma totalmente local en el dispositivo.

El proceso de clasificación se desarrolla según el pipeline que se describe a continuación:

1. Carga del modelo desde los assets de la aplicación (avocado_model.tflite) durante la inicialización del módulo.
2. Decodificación de la imagen con el paquete image de Dart.
3. Redimensionamiento bilineal a 224×224 píxeles para ajustarse a la forma de entrada que exige la arquitectura MobileNetV2.
4. Normalización de los valores RGB: cada canal se divide entre 255.0 para situar los valores en el rango [0.0, 1.0].
5. Construcción del tensor de entrada Float32 con forma [1, 224, 224, 3].
6. Ejecución de la inferencia a través del intérprete TFLite.
7. Se obtiene el vector de salida [1, 3] con las probabilidades de mancha_negra, ronia y sana.
8. Se selecciona la clase de mayor probabilidad (argmax) como predicción.
9. Se devuelve un objeto DetectionResult con el tipo de enfermedad y su nivel de confianza.

El modelo asigna el fruto a una de tres categorías Sana, Mancha Negra o Roña y ofrece recomendaciones fitosanitarias específicas según la enfermedad detectada, mediante los métodos getRecommendationES() y getRecommendationEN().

Figura 13
Resultado de clasificación mostrando diagnóstico, confianza y recomendaciones.



Módulo de Visualización de Resultados

El módulo de visualización de resultados se compone de dos elementos complementarios que permiten al usuario interpretar tanto el diagnóstico individual de un fruto como el historial acumulado de análisis.

Card de Resultado Individual

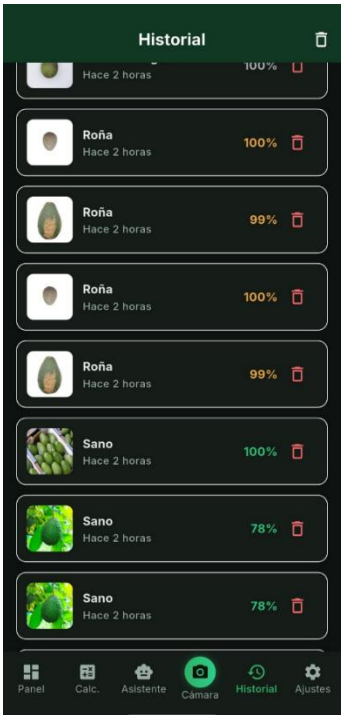
Al concluir la detección de un fruto la pantalla de la cámara muestra una tarjeta de los resultados que se obtuvo, junto con un icono de estado según el color el verde para sano, naranja para mancha negra y rojo para roña, teniendo el nombre de la enfermedad detectada, el porcentaje de confianza y recomendaciones fitosanitarias que corresponden a la detección.

Pantalla de Historial de Detecciones

La pantalla Historial lista los análisis en orden cronológico de cómo fueron salieron en análisis del modelo, recuperados de la base de datos SQLite local, cada entrada muestra el tipo de enfermedad, el nivel de confianza, la fecha y hora, y el estado (roña/mancha negra/sano).

Desde la misma pantalla se pueden ver el detalle de la enfermedad e iniciar una conversación con el asistente de IA para saber más información como también borrar registros o vaciar el historial.

Figura 14
Módulo de historial mostrando detecciones previas con color por estado.



Módulo de Configuración y Versionamiento

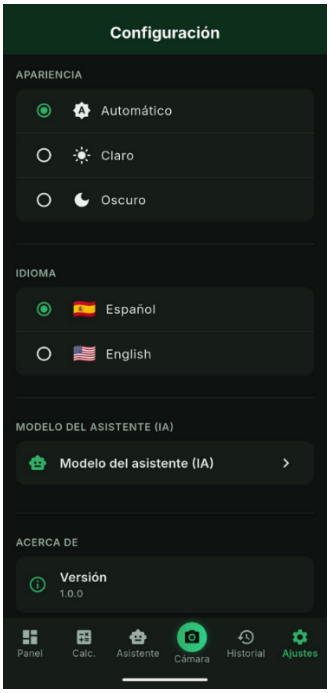
La pantalla de Configuración reúne las opciones de personalización de la aplicación y la información de versión del sistema, y se organiza en tres secciones:

- Selector de idioma: permite al usuario alternar entre español e inglés mediante botones de opción, modificando el idioma en toda la aplicación.

- Información de la aplicación: muestra la versión vigente del sistema (v1.0.0), la descripción de la aplicación y la lista de enfermedades detectables (Mancha Negra, Roña y Fruto Sano).
- Acerca del proyecto: señala que se trata de un proyecto de investigación de la Universidad de las Fuerzas Armadas ESPE.
- El versionamiento de la aplicación se administra mediante el archivo pubspec.yaml de Flutter, en el que la versión actual es 1.0.0+1. Este esquema permite distribuir futuras actualizaciones del modelo TFLite como nuevas versiones de la aplicación, sin necesidad de modificar la estructura del código fuente.

Figura 15

Pantalla de configuración con selector de idioma e información de versión.



Módulo de Resumen y Estadísticas

El módulo de resumen y estadísticas se materializa en dos componentes integrados el Dashboard o panel de control general y la Calculadora de Incidencia, que ofrecen al agricultor una visión cuantitativa del estado fitosanitario de su cultivo.

Dashboard (Panel de Control)

La pantalla Dashboard (DashboardPage) ofrece una síntesis visual de todas las detecciones guardadas en la base de datos local e incorpora los siguientes elementos de visualización:

- Tarjetas de resumen: cuatro tarjetas presentan el total de análisis, los frutos sanos, los afectados por Mancha Negra y los afectados por Roña, cada una con su color e ícono.
- Gráfico de torta: representa en porcentajes las tres categorías roña, mancha negra y sanos mediante la librería fl_chart.
- Actividad reciente: lista las últimas cinco detecciones con su tipo de enfermedad y su marca temporal.
- Las estadísticas las calcula DetectionProvider a partir de consultas SQL sobre detection_results, y el dashboard se actualiza de forma automática.

Figura 16
Dashboard con tarjetas de resumen y gráfico de distribución de enfermedades.



Calculadora de Incidencia de Enfermedades

La Calculadora (CalculatorPage) es una herramienta complementaria que ayuda al agricultor a estimar la incidencia de enfermedades en un lote de frutos. Para ello, el usuario introduce el número total de frutos y la cantidad correspondiente a cada categoría (sanos, con Mancha Negra y con Roña).

Tabla 14

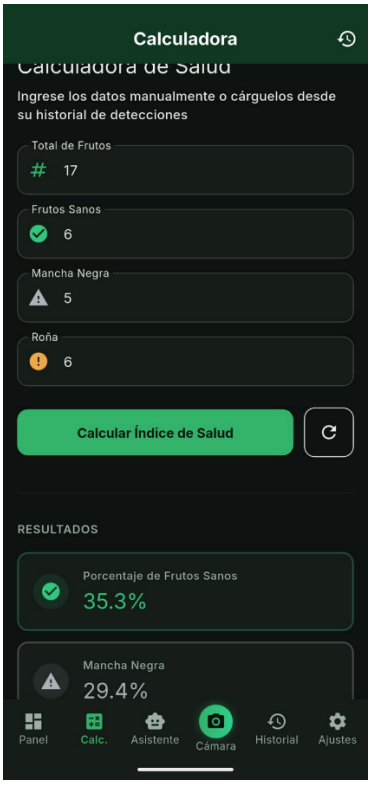
Niveles de alerta fitosanitaria de la calculadora de incidencia.

Nivel de Alerta	Incidencia	Recomendación
Excelente - Verde	< 10 %	Continuar con prácticas de manejo. Monitoreo preventivo.
Alerta - Amarillo	10 – 25 %	Incrementar frecuencia de monitoreo. Aplicación preventiva de fungicidas.
Crítico - Rojo	> 25 %	Acción inmediata requerida. Tratamiento fungicida urgente. Eliminar material vegetal infectado.

Nota. Elaboración propia.

Figura 17

Calculadora de incidencia con resultado y nivel de alerta fitosanitaria.

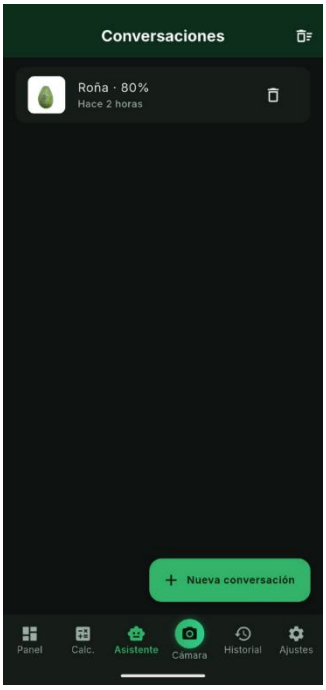


Módulo de Asistente Virtual

El módulo de asistente virtual corresponde a la pantalla Asistente y ofrece al agricultor un canal de consulta conversacional dentro de la propia aplicación. El productor puede escribir su pregunta o dictarla por voz.

Con el asistente resuelve dudas sobre la mancha negra y la roña, interpreta el resultado de un diagnóstico y consulta recomendaciones de manejo fitosanitario sin salir de la aplicación.

Figura 18
Pantalla de Asistente de recomendaciones



Tecnologías Utilizadas

El desarrollo del sistema Avocado IA abarca dos entornos tecnológicos diferenciados: el de entrenamiento del modelo de inteligencia artificial, sustentado en Python y TensorFlow, y el de desarrollo de la aplicación móvil, basado en Flutter/Dart. Las tecnologías empleadas en cada uno se detallan en la **Tabla 15** y la **Tabla 16**.

Tecnologías del Entorno de Entrenamiento del Modelo

Tabla 15

Tecnologías utilizadas en el entorno de entrenamiento del modelo CNN.

Tecnología	Rol en el proyecto
Python 3.12	Lenguaje del entorno de entrenamiento.
TensorFlow 2.19.0	Framework de *deep learning*: construye y entrena la CNN
Keras (API de TF)	Define la arquitectura de capas.
MobileNetV2	Arquitectura base preentrenada con ImageNet; se aprovecha por *transfer learning*
TensorFlow Lite	Convierte el modelo para inferencia en móviles y dispositivos embebidos
ImageDataGenerator	Carga las imágenes por lotes y aplica aumento de datos
Scikit-learn	Calcula las métricas de evaluación: [¿precisión, recall, F1, matriz de confusión?]
NumPy	Manipula arrays y tensores numéricos
Matplotlib / Seaborn	Grafica [¿curvas de entrenamiento y matriz de confusión?]
Google Colab (GPU T4)	Entorno de ejecución en la nube
Google Drive	Almacena el conjunto de datos etiquetado

Nota. Elaboración propia.

Tecnologías del Entorno de Desarrollo de la Aplicación Móvil

Tabla 16

Paquetes y tecnologías utilizados en el desarrollo de la aplicación móvil Avocado IA.

Paquete / Tecnología	Función en la aplicación
Flutter SDK 3.x	Framework multiplataforma para desarrollo de la aplicación móvil Android/iOS
Dart 3.9.2	Lenguaje de programación orientado a objetos base de Flutter
provider ^6.1.1	Gestión de estado mediante el patrón Observer/ChangeNotifier
sqflite ^2.3.0	Acceso a la base de datos SQLite local para persistencia de detecciones
image_picker ^1.0.7	Captura de imagen desde la cámara o galería del dispositivo
image ^4.1.7	Decodificación, redimensionamiento y normalización de imágenes en Dart
path_provider ^2.1.1	Acceso a directorios del sistema de archivos del dispositivo
fl_chart ^0.66.0	Generación de gráficos interactivos (PieChart) en el Dashboard
connectivity_plus ^5.0.2	Detección del estado de conectividad de red para el modo offline

flutter_localizations	Soporte de internacionalización para los idiomas español e inglés
lottie ^3.0.0	Reproducción de animaciones Lottie en la interfaz de usuario
shared_preferences ^2.2	Persistencia de preferencias del usuario (idioma seleccionado)
Material Design 3	Sistema de diseño visual de Google aplicado a todos los componentes UI

Nota. Elaboración propia.

Funcionamiento general del prototipo

El prototipo Avocado IA es un sistema autónomo de diagnóstico fitosanitario para los dispositivos móviles de los agricultores. Al operar sin conexión a internet, resulta especialmente apropiado para las zonas rurales con escasa infraestructura. A continuación, se describe su flujo de trabajo desde la perspectiva del usuario final.

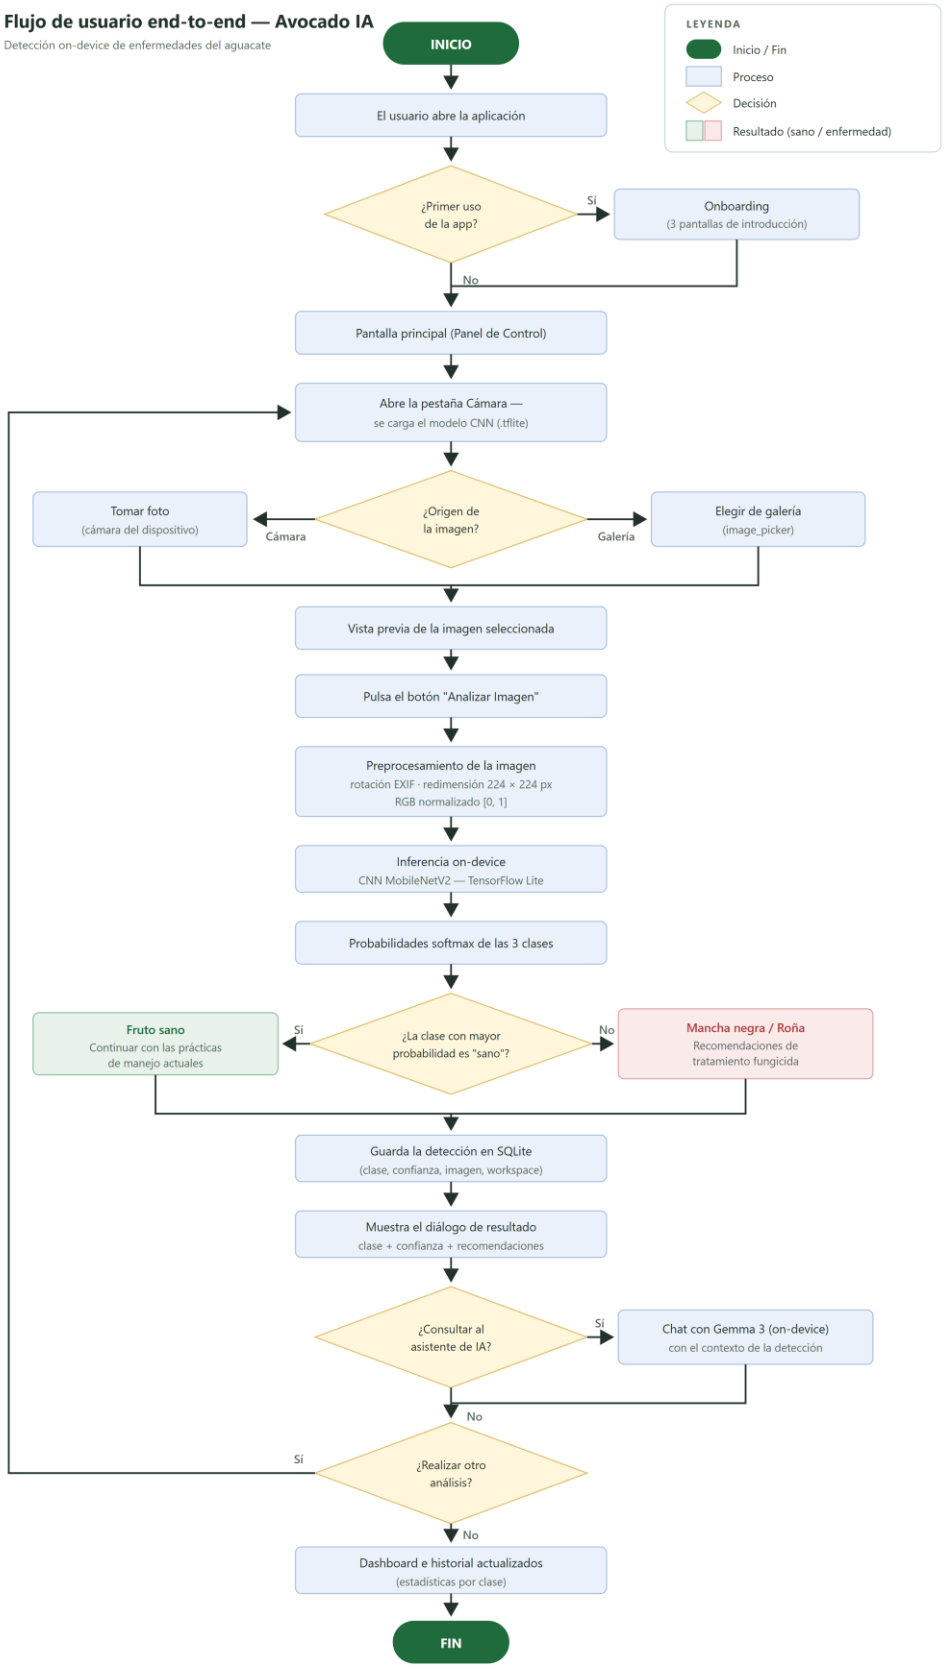
Flujo de Usuario End-to-End

El flujo de uso habitual del prototipo sigue la secuencia de pasos que ilustra la **Figura 19** y que se detalla a continuación:

1. Inicio de la aplicación. El usuario abre Avocado IA en su dispositivo móvil; la aplicación inicializa los providers (DetectionProvider, LocaleProvider, ConnectivityProvider) y carga el modelo TFLite desde los assets.
2. El usuario accede a la opción de Cámara a través del BottomNavigationBar ubicada en la parte inferior y el módulo de captura inicializa TFLite.
3. El usuario puede fotografiar un aguacate o elegir una imagen existente de la galería, al elegir o tomar la imagen se muestra una vista previa de 400 px en la pantalla.
4. Al pulsar "**Analizar**", la aplicación procesa la imagen en un promedio de 3 segundos en dispositivos con 2 GB de RAM, mientras exhibe un indicador de carga miestras procesa internamente la imagen con el modelo.

5. El resultado del análisis se presenta en una tarjeta con código de color verde (Sano), negro (Mancha Negra) o naranja (Roña), junto con el porcentaje de confianza del resultado obtenido y las recomendaciones fitosanitarias; asimismo, se muestra un diálogo modal con el resumen del diagnóstico.
6. El historial se guarda automáticamente se guarda en la base de datos SQLite local del dispositivo móvil con los detalles del análisis, como el tipo de enfermedad que dio el análisis.
7. El usuario abre el Dashboard para ver el resumen de los análisis: los gráficos de distribución y la actividad reciente.
8. Si quiere, el agricultor usa la Calculadora para estimar la incidencia de enfermedades en todo un lote. Carga los datos desde el historial o los introduce a mano, y recibe una alerta fitosanitaria con recomendaciones de manejo según el nivel de incidencia calculado.

Figura 19
Diagrama de flujo del usuario end-to-end en el prototipo Avocado IA.


Flujo de usuario end-to-end — Avocado IA
Detección on-device de enfermedades del aguacate
LEYENDA
Inicio / Fin
Proceso
Decisión
Resultado (sano / enfermedad)
INICIO
El usuario abre la aplicación
¿Primer uso de la app?
Sí
Onboarding
(3 pantallas de introducción)
No
Pantalla principal (Panel de Control)
Abre la pestaña Cámara — se carga el modelo CNN (.tflite)
¿Origen de la imagen?
Cámara
Tomar foto
(cámara del dispositivo)
Galería
Elegir de galería
(image_picker)
Vista previa de la imagen seleccionada
Pulsa el botón "Analizar Imagen"
Preprocesamiento de la imagen
rotación EXIF · redimensión 224 × 224 px
RGB normalizado [0, 1]
Inferencia on-device
CNN MobileNetV2 — TensorFlow Lite
Probabilidades softmax de las 3 clases
¿La clase con mayor probabilidad es "sano"?
Sí
Fruto sano
Continuar con las prácticas de manejo actuales
No
Mancha negra / Roña
Recomendaciones de tratamiento fungicida
Guarda la detección en SQLite
(clase, confianza, imagen, workspace)
Muestra el diálogo de resultado
clase + confianza + recomendaciones
¿Consultar al asistente de IA?
Sí
Chat con Gemma 3 (on-device)
con el contexto de la detección
No
¿Realizar otro análisis?
Sí
No
Dashboard e historial actualizados
(estadísticas por clase)
FIN

Capítulo V

Resultados y validación

Escenario y condiciones de prueba

La evaluación del modelo se llevó a cabo sobre el conjunto de datos balanceado descrito en el capítulo anterior, formado por 2999 imágenes de frutos de aguacate repartidas de forma casi uniforme entre las tres categorías de interés mancha negra, roña y fruto sano, con cerca de 1000 imágenes por clase (1000, 1000 y 999, respectivamente), esta distribución equilibrada se implementó de manera deliberada, pues un conjunto balanceado permite estimar el desempeño de cada clase sin que la métrica global quede dominada por la categoría más numerosa, estos sesgos que distorsionan la interpretación de los resultados obtenidos en el entrenamiento cuando las clases están desproporcionadas.

El conjunto se dividió en tres particiones mediante un muestreo estratificado, con proporciones del 70 % para entrenamiento, el 15 % para validación y el 15 % para prueba, lo que arrojó como resultado de nuestras muestras dadas: 2099 imágenes de entrenamiento, 449 de validación y 451 de prueba por cada categoría (roña, mancha negra y sano). Con el fin de que los resultados fueran reproducibles entre ejecuciones, la partición se generó con una semilla aleatoria fija de 42. El subconjunto de prueba se mantuvo por completo al margen del entrenamiento y la validación, de modo que las métricas presentadas en este capítulo reflejan el comportamiento del modelo ante imágenes que no participaron en el ajuste de sus parámetros.

Antes de la inferencia, cada imagen se redimensionó a 224 × 224 píxeles y sus valores RGB se normalizaron al rango [0, 1]. El entrenamiento se ejecutó en Google Colab con aceleración por GPU T4, y la evaluación se realizó tanto sobre el modelo en formato Keras como sobre su

versión convertida a TensorFlow Lite, con el propósito de comprobar que la optimización para dispositivos móviles no deteriorara de forma apreciable la capacidad de clasificación.

Evaluación del modelo CNN

La evaluación del modelo se estructuró en dos partes. En la primera se analiza el comportamiento observado durante el entrenamiento, a partir de la evolución de sus métricas época a época; en la segunda se exponen los resultados finales sobre los conjuntos de validación y prueba, junto con la comparación frente a una arquitectura alternativa y el efecto de la conversión a TensorFlow Lite.

Resultados de entrenamiento

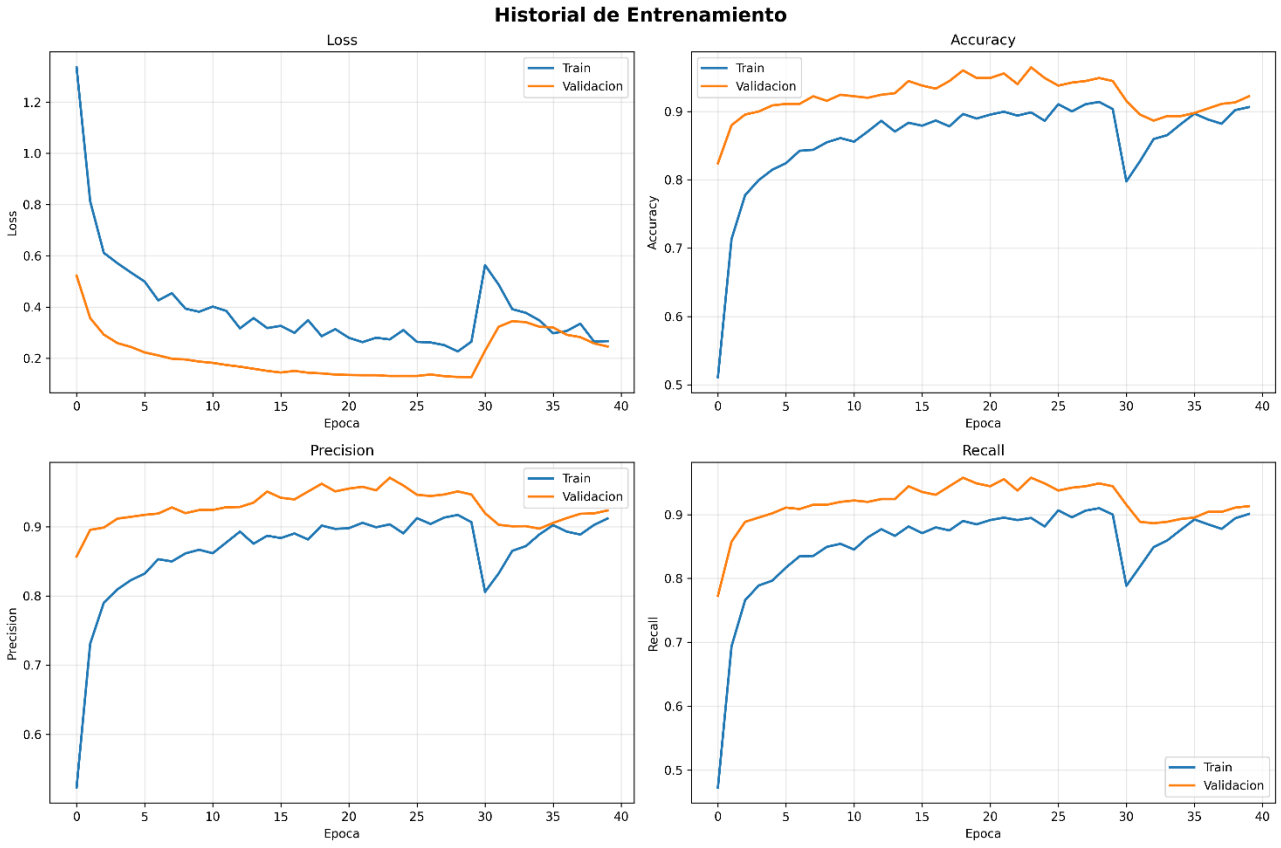
El modelo se entrenó según la estrategia de aprendizaje por transferencia definida en la metodología, en dos fases. En la primera fase se congeló la base convolucional de MobileNetV2 y se entrenó solo un clasificador denso sobre ella. Se usó Adam con tasa de aprendizaje inicial de 1×10^{-4}, entropía cruzada categórica como función de pérdida y lotes de 32 imágenes, durante 30 épocas; el mejor desempeño en validación se dio en la época 24. La segunda fase fue de fine-tuning: se descongeló la base a partir de la capa 100 y se reentrenaron diez épocas más con una tasa de 1×10^{-5}, con parada temprana en la época 40. Dado que esta fase no mejoró el desempeño en validación, el modelo final conservó los pesos de la fase con base congelada. Para contener el sobreajuste se emplearon, además, la reducción adaptativa de la tasa de aprendizaje y el guardado del mejor modelo.

En la **Figura 20** se muestran las curvas de pérdida, exactitud, precisión y exhaustividad a lo largo de las dos fases de entrenamiento. Durante la primera fase, con la base congelada, la pérdida de entrenamiento y validación descendió de forma sostenida y las métricas crecieron hasta estabilizarse, alcanzando el mejor desempeño de validación hacia la época 24. Al iniciar la segunda

fase de fine-tuning (época 31) se aprecia una alteración transitoria en las curvas consecuencia de descongelar la base, tras la cual el desempeño de validación no superó el de la fase congelada. La cercanía entre las curvas de entrenamiento y validación indica que el modelo aprendió patrones generalizables y no memorizó el conjunto de entrenamiento, comportamiento coherente con el uso del aumento de datos y de las capas de abandono.

Figura 20

Curvas de pérdida, exactitud, precisión y exhaustividad del modelo balanceado durante el entrenamiento.



Resultados de validación y prueba

El desempeño definitivo del modelo se midió sobre el conjunto de prueba, integrado por 451 imágenes balanceadas ajenas al entrenamiento y a la validación. La **Tabla 17** recoge el valor F1 obtenido en cada clase y su promedio macro.

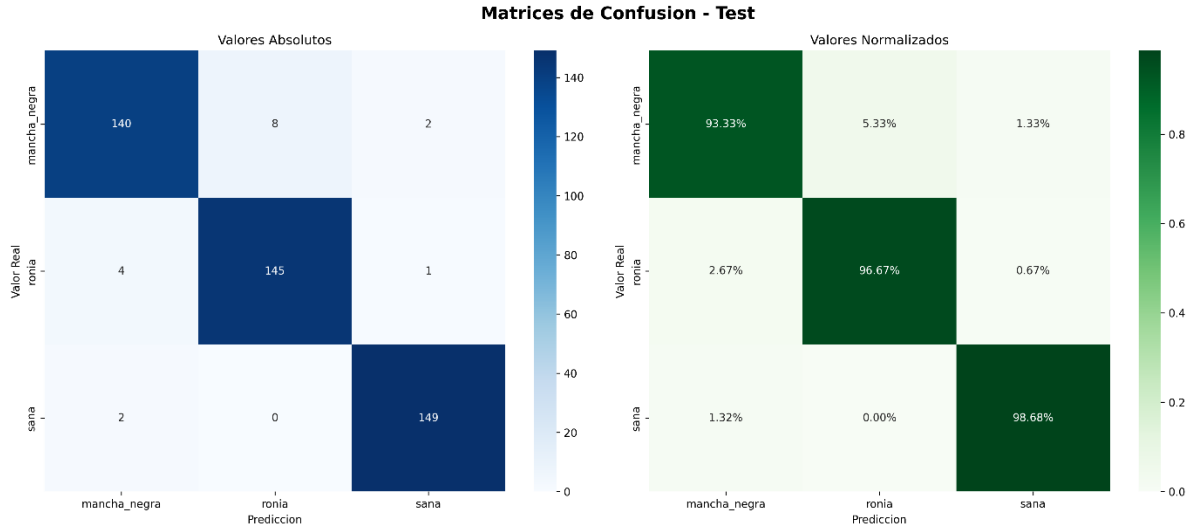
Tabla 17
Desempeño por clase del modelo en el conjunto de prueba balanceado.

Clase	F1-score (%)
Mancha negra	94.59
Roña	95.71
Fruto sano	98.35
Promedio macro	**96.22**

Nota. Elaboración propia.

El modelo superó el 94 % de F1 en las tres categorías, con una exactitud global del 96.23 % y un valor F1 macro del 96.22 %. La clase mejor reconocida fue el fruto sano, con un F1 del 98.35 %, resultado atribuible a su aspecto homogéneo y claramente diferente del de un fruto con lesiones. La roña y la mancha negra registraron valores algo inferiores, del 95.71 % y el 94.59 %, respectivamente. Como se aprecia en la matriz de confusión de la **Figura 21**, la mayoría de las predicciones se concentra en la diagonal principal y los escasos errores de clasificación se producen sobre todo entre la mancha negra y la roña, algo previsible si se tiene en cuenta que ambas se presentan como lesiones oscuras sobre la epidermis del fruto y comparten rasgos visuales.

Figura 21
Matriz de confusión del modelo en el conjunto de prueba balanceado.



Con el fin de sustentar la elección de la arquitectura, se compararon MobileNetV2 y EfficientNet-B0 en igualdad de condiciones: ambos se entrenaron durante 20 épocas con la base congelada y sin fine-tuning. La **Tabla 18** concentra estos resultados.

Tabla 18

Comparación de arquitecturas en igualdad de condiciones (20 épocas, base congelada).

Modelo (20 épocas, base congelada)	Exactitud (%)	Macro-F1 (%)	Parámetros
MobileNetV2	93.35	93.37	3 049 027
EfficientNet-B0	95.12	95.14	4 840 614

Nota. Elaboración propia. Ambos modelos se entrenaron 20 épocas con la base congelada, sin fine-tuning.

En igualdad de condiciones 20 épocas y base congelada, sin fine-tuning, EfficientNet-B0 alcanzó una exactitud del 95,12 % frente al 93,35 % de MobileNetV2. Pese a este mejor desempeño en exactitud, se optó por MobileNetV2 por razones decisivas para el despliegue móvil:

cuenta con cerca de un 37 % menos de parámetros (3,05 millones frente a 4,84 millones), lo que se traduce en un modelo más liviano, con menor consumo de memoria y una inferencia más rápida en teléfonos de gama media. El modelo MobileNetV2 definitivo, entrenado con el pipeline completo, alcanzó una exactitud del 96,23 %; tras su conversión a TensorFlow Lite descendió a 96,01 % apenas 0,22 puntos porcentuales, lo que confirma que la cuantización no compromete la calidad del diagnóstico.

Evaluación del prototipo en campo

La aplicación Avocado IA se validó funcionalmente en un entorno de desarrollo controlado, con el objetivo de verificar que el flujo completo de diagnóstico funciona correctamente en un dispositivo móvil real. Se comprobó que la aplicación carga el modelo en formato TensorFlow Lite desde sus recursos internos durante la inicialización y que ejecuta las etapas de captura de imagen, preprocesamiento, inferencia y presentación del resultado sin necesidad de conexión a internet. Las capturas de pantalla incluidas en el capítulo previo evidencian el comportamiento del prototipo en cada módulo: la obtención de la imagen desde la cámara o la galería como se muestra en la Figura 12 ,la clasificación del fruto con su nivel de confianza y sus recomendaciones fitosanitarias como se observa en la Figura 13, el registro del análisis en el historial local que se muestra en la Figura 14, el resumen estadístico del panel de control mostrado en la Figura 16 y el cálculo de la incidencia por lote que se muestra en la Figura 17.

Durante estas pruebas realizadas con cada uno de las categorías (roña, mancha negra y sano) se verificó que el modelo embebido en el dispositivo móvil genera un diagnóstico coherente con la categoría del fruto fotografiado o cargado desde la galería y que la información se guarda de forma persistente en la base de datos SQLite del dispositivo, todos estos resultados fueron

comprobados funciona correctamente sin conexión, así mismo para poder acceder al modelo de asistencia de IA para cada resultado se incorporo una calve de accesos ligero donde, primero el usuario ingresa la contraseña y se desbloquea la pantalla, se descarga el modelo de lenguaje Gemma 3, donde este modelo nos ayuda a resolver dudas y recibir recomendaciones sobre el manejo de las enfermedades de forma que se ejecuta todo localmente dentro del dispositivo y sin conexión a internet.

Ahora bien, esta validación se circunscribió al funcionamiento técnico del prototipo y no representa aún una evaluación en campo con usuarios finales. La prueba del sistema con agricultores en las condiciones reales de un huerto con variaciones de iluminación, distintos modelos de teléfono y la valoración de la utilidad percibida por los productores no se ha llevado a cabo por el momento y se propone como una fase posterior del trabajo, tal como se detalla en las recomendaciones del capítulo siguiente.

Análisis de resultados

Los resultados obtenidos confirman que la arquitectura propuesta resuelve de forma satisfactoria la tarea de clasificación planteada en el objetivo de este trabajo. El empleo de un conjunto de datos balanceados y validados incidió directamente en el reconocimiento de la mancha negra, que en versiones preliminares con datos desproporcionados mostraba un desempeño inferior debido a su escasa representación; al igualar el número de ejemplos por clase, el valor F1 de esta categoría se situó por encima del 94 %, a la par del resto de las clases.

La comparación entre MobileNetV2 y EfficientNet-B0 respalda la elección de la primera (MobileNetV2) para el escenario móvil, aunque no por su exactitud exactamente ya que en igualdad de condiciones, EfficientNet-B0 obtuvo una exactitud algo superior (95,12 % frente a 93,35 %), pero MobileNetV2 obtuvo ese resultad cercano con un tercio menos de parámetros de

los que tiene EfficientNet-B0, lo que se traduce en un modelo más liviano, con menor demanda de memoria y una inferencia más veloz, donde estas cualidades son decisivas para ejecutarse sin conexión en teléfonos de gama media.

La conversión del modelo final a TensorFlow Lite redujo su tamaño en un 82 % con una pérdida de exactitud de apenas 0,22 puntos porcentuales, de manera que el modelo obtenido cuantizado resulta completamente utilizable en el dispositivo sin un costo relevante en desempeño.

Cabe recalcar el papel del afinamiento o conocido como fine-tuning: se aplicó como segunda fase, descongelando las capas superiores de MobileNetV2, pero se observó que no mejoró el desempeño en el conjunto de validación respecto a la fase con base congelada, por lo que el modelo final conservó los pesos de esta última. Esto indica que las características aprendidas por MobileNetV2 sobre ImageNet donde se transfieren adecuadamente al dominio de las lesiones en frutos de aguacate y que, con el tamaño de conjunto disponible, en resumen, se pudo llegar a un resultado que descongelar la base no aportaba una ganancia capaz de justificar el mayor riesgo de sobreajuste ni el costo computacional adicional.

Discusión de resultados

Los valores alcanzados por el modelo se inscriben dentro del rango informado en el estado del arte. Los estudios que utilizan conjuntos controlados, como PlantVillage, suelen reportar exactitudes cercanas al 99%, mientras que los que emplean imágenes tomadas en campo se ubican con mayor frecuencia entre el 78% y el 95%. La exactitud del 96.23 % obtenida como resultado en este trabajo, sobre un conjunto construido en su mayor parte con fotografías captadas directamente en una finca del cantón Sigchos, resulta competitiva e indica que el modelo conserva un desempeño sólido frente a la variabilidad propia del entorno real, justamente donde muchos modelos entrenados en laboratorio pierden eficacia.

El trabajo cubre tres de los vacíos detectados en la revisión. El primero es la atención al aguacate específicamente a enfermedades como lo son la mancha negra y la roña en cultivo, unas patologías donde son escasamente tratadas mediante redes neuronales convolucionales frente a la abundante producción académica sobre manzana, uva o cítricos. El segundo es la evaluación con un conjunto propio, balanceado y validado, que acorta la distancia entre la precisión informada y el comportamiento esperable en campo. El tercero es el despliegue del modelo en una aplicación móvil capaz de operar sin conexión, que da como respuesta a la brecha digital que existe en las zonas rurales del Ecuador, donde la dependencia de servicios en la nube restringe el uso de herramientas de diagnóstico.

No obstante, los resultados deben interpretarse a la luz de las limitaciones del estudio, donde el conjunto de datos, aun estando balanceado, procede principalmente de una única localidad y de tipos de aguacates seleccionados como lo son Hass verde y el guatemalteco, por lo que su representación es limitada frente a otras zonas productoras y otras variedades de aguacate.

El sistema reconoce solo dos enfermedades y el estado sano, de modo que otras patologías del cultivo quedan fuera de su alcance asi como la predicción de otros objetos que no es el fruto. La leve diferencia que se presentó en el desempeño del modelo en la mancha negra y la roña respecto al fruto sano puede deberse a la semejanza visual entre ambas lesiones oscuras, que provoca confusiones ocasionales.

Capítulo VI

Conclusiones y recomendaciones

Conclusiones

El trabajo cumplió con el objetivo general de implementar un modelo optimizado de aprendizaje profundo para la detección temprana de enfermedades en el aguacate que se

especificaron como: la roña y la mancha negra, mediante visión por computadora. El modelo construido e implementado es sustentado en MobileNetV2 con aprendizaje por transferencia, donde los resultados alcanzaron una exactitud global del 96.23% y un valor F1 macro del 96.22% sobre un conjunto de datos donde fueron balanceados e independientes, con valores por clase o categorías superiores al 94%, lo que evidencia su capacidad para distinguir de manera fiable entre las dos enfermedades y el fruto sano.

La revisión del estado del arte permitió identificar las arquitecturas, las tendencias y los vacíos de la detección automatizada de enfermedades en frutas, y sentó las bases para elegir una arquitectura ligera orientada al despliegue móvil, donde a partir de ese análisis se seleccionó MobileNetV2, donde esta comparación con EfficientNet-B0 confirmó que, si bien EfficientNet-B0 alcanzó una exactitud ligeramente superior en cuanto a los resultados, MobileNetV2 ofrece un mejor equilibrio para el despliegue en dispositivos móviles, cubriendo así hasta los dispositivos de baja gama.

Se construyó y valido un conjunto de datos propio de frutos de aguacate, capturado en campo y complementado con repositorios públicos, que se organizó de forma balanceada con aproximadamente 1000 imágenes por categoría, cada una validada por un experto de la zona. Este equilibrio fue determinante para el desempeño del modelo, ya que corrigió el bajo reconocimiento de la mancha negra observado cuando las clases estaban desproporcionadas y permitió alcanzar la distribución de 2999 imágenes (1000, 1000 y 999 por clase) prevista entre los objetivos del proyecto.

El modelo se integró en la aplicación móvil llamada Avocado IA que se desarrolló en Flutter, donde se ejecuta localmente mediante TensorFlow Lite y opera sin conexión a internet, con un tamaño final del modelo de 3.2 MB, la aplicación permite capturar la imagen desde la

cámara o cargar la imagen desde galería y asi obtener el diagnóstico con su nivel de confianza y brindar recomendaciones de cuidado del fruto, registrar el historial de detecciones y estimar la incidencia de enfermedades por lote, todo ello en el propio dispositivo del agricultor.

Recomendaciones y trabajo futuro

A partir de la experiencia adquirida y de las limitaciones observadas, se proponen varias líneas de continuidad para el proyecto.

La más inmediata consiste en hacer más validaciones del prototipo en campo con agricultores, mediante pruebas en huertos reales que permitan medir la exactitud del sistema en condiciones no controladas, registrar el tiempo de respuesta en distintos modelos de teléfono y recabar la valoración de los usuarios sobre su utilidad y facilidad de uso. Esta etapa es imprescindible para confirmar que el desempeño obtenido en el conjunto de prueba se mantiene en el uso cotidiano.

Conviene, asimismo, ampliar el conjunto de datos con imágenes de otras localidades productoras y de otras variedades de aguacate, sumando un mayor número de ejemplos de mancha negra y, llegado el caso, nuevas enfermedades del cultivo. Un conjunto más amplio y diverso posibilitaría reevaluar el ajuste fino que con los datos actuales no mejoró el desempeño y, probablemente, incrementaría la robustez del modelo frente a la variabilidad del entorno.

En cuanto a la aplicación, sería aconsejable incorporar mecanismos que expliquen los resultados de mejora manera, como mapas de calor que resalten las partes del aguacate que motivan el diagnóstico a una mejor interpretación y reforzar la confianza del agricultor en el resultado.

La sincronización opcional con un servicio en la nube permitiría respaldar el historial y a mayor escala, generar información epidemiológica agregada sobre la presencia de enfermedades

en distintas zonas, todo esto unificado mediante una aplicación web donde se lleva el control y registro ya sea por huerto o por agricultor.

Finalmente, dado que la mancha negra y la roña muestran cierta semejanza visual, los trabajos futuros podrían centrarse en mejorar la discriminación entre ambas lesiones con mayor número de muestras por cada categoría, ya sea utilizando técnicas de aumento específicas o con arquitecturas basadas en mecanismos de atención.

Referencias

Çetiner, H. (2022). Citrus disease detection and classification using based on convolution deep neural network. *Microprocessors and Microsystems*, *95*, 104687. https://doi.org/10.1016/J.MICPRO.2022.104687

Goel, S., & Pandey, K. (1 C.E.). A Survey on Deep Learning Techniques in Fruit Disease Detection. *Https://Services.Igi-Global.Com/Resolvedoi/Resolve.Aspx?Doi=10.4018/IJDST.307901*, *13*(8), 1–19. https://doi.org/10.4018/IJDST.307901

He, K., Zhang, X., Ren, S., & Sun, J. (2016). Deep residual learning for image recognition. *Proceedings of the IEEE Computer Society Conference on Computer Vision and Pattern Recognition*, *2016-December*, 770–778. https://doi.org/10.1109/CVPR.2016.90

Howard, A. G., Zhu, M., Chen, B., Kalenichenko, D., Wang, W., Weyand, T., Andreetto, M., & Adam, H. (2017). *MobileNets: Efficient Convolutional Neural Networks for Mobile Vision Applications*. https://arxiv.org/pdf/1704.04861

Jiang, P., Chen, Y., Liu, B., He, D., & Liang, C. (2019). Real-Time Detection of Apple Leaf Diseases Using Deep Learning Approach Based on Improved Convolutional Neural Networks. *IEEE Access*, *7*, 59069–59080. https://doi.org/10.1109/ACCESS.2019.2914929

Kavya, P., Nischitha, S., Nivedita, N. S., & Prabhu, A. (2024). Deep Analysis: Apple Fruit Disease Detection Using Deep Learning. *2024 IEEE International Conference on Information Technology*,

Electronics and Intelligent Communication Systems, ICITEICS 2024. https://doi.org/10.1109/ICITEICS61368.2024.10625593

Khattak, A., Asghar, M. U., Batool, U., Asghar, M. Z., Ullah, H., Al-Rakhami, M., & Gumaei, A. (2021). Automatic Detection of Citrus Fruit and Leaves Diseases Using Deep Neural Network Model. *IEEE Access*, *9*, 112942–112954. https://doi.org/10.1109/ACCESS.2021.3096895

Komala, K. V., Lata, B. T., & Venugopal, K. R. (2023). Deep Learning for Accurate Vineyard Pathology Detection. *2023 IEEE 5th PhD Colloquium on Emerging Domain Innovation and Technology for Society, PhD EDITS 2023*. https://doi.org/10.1109/PHDEDITS60087.2023.10373754

Krizhevsky, A., Sutskever, I., & Hinton, G. E. (2017). ImageNet classification with deep convolutional neural networks. *Communications of the ACM*, *60*(6), 84–90. https://doi.org/10.1145/3065386;CSUBTYPE:STRING:MAGAZINE;PAGE:STRING:ARTICLE/CHAPTER

Lecun, Y., Bengio, Y., & Hinton, G. (2015). Deep learning. *Nature*, *521*(7553), 436–444. https://doi.org/10.1038/NATURE14539;SUBJMETA

Liakos, K. G., Busato, P., Moshou, D., Pearson, S., & Bochtis, D. (2018). Machine Learning in Agriculture: A Review. *Sensors 2018, Vol. 18, Page 2674*, *18*(8), 2674. https://doi.org/10.3390/S18082674

Marais, L. J. (2004). Avocado Diseases of Major Importance Worldwide and their Management. *Diseases of Fruits and Vegetables: Volume II*, 1–36. https://doi.org/10.1007/1-4020-2607-2_1

Matboli, M. A., & Atia, A. (2022). Fruit Disease's Identification and Classification Using Deep Learning Model. *MIUCC 2022 - 2nd International Mobile, Intelligent, and Ubiquitous Computing Conference*, 432–437. https://doi.org/10.1109/MIUCC55081.2022.9781688

Mexicana de Fitopatología, S., México Ávila Quezada, A., Dolores, G., Ortiz, T., Aguilera, M., Huerta, V., & Chávez, T. (2003). *Spatial and Temporal Dynamic of Scab (Sphaceloma perseae Jenk.) on Avocado (Persea americana Mill) Revista Mexicana de Fitopatología*. *21*(2), 152–160. http://www.redalyc.org/articulo.oa?id=61221209

Mohanty, S. P., Hughes, D. P., & Salathé, M. (2016). Using deep learning for image-based plant disease detection. *Frontiers in Plant Science*, *7*(September), 215232. https://doi.org/10.3389/FPLS.2016.01419/TEXT

Patel, H. B., & Patil, N. J. (2024). Enhanced CNN for Fruit Disease Detection and Grading Classification Using SSDAE-SVM for Postharvest Fruits. *IEEE Sensors Journal*, *24*(5), 6719–6732. https://doi.org/10.1109/JSEN.2023.3342833

Peñafiel, G. E. S., Peñafiel, G. E. S., Velasco, M. V. E., Lescano, Á. A. F., & Angamarca, D. K. C. (2023). Diagnóstico del uso de aplicaciones móviles para el estudio de enfermedades del café. *Polo Del Conocimiento*, *8*(4), 1883–1896. https://doi.org/10.23857/pc.v8i4.5535

Sandler, M., Howard, A., Zhu, M., Zhmoginov, A., & Chen, L. C. (2018). MobileNetV2: Inverted Residuals and Linear Bottlenecks. *Proceedings of the IEEE Computer Society Conference on Computer Vision and Pattern Recognition*, 4510–4520. https://doi.org/10.1109/CVPR.2018.00474

Sharma, A., Jain, A., Gupta, P., & Chowdary, V. (2021). Machine Learning Applications for Precision Agriculture: A Comprehensive Review. *IEEE Access*, *9*, 4843–4873. https://doi.org/10.1109/ACCESS.2020.3048415

Sharma, R., Kukreja, V., & Bordoloi, D. (2023). Deep Learning Meets Agriculture: A Faster RCNN Based Approach to pepper leaf blight disease Detection and Multi-Classification. *2023 4th International Conference for Emerging Technology, INCET 2023*. https://doi.org/10.1109/INCET57972.2023.10170692

Singh, G., Guleria, K., & Sharma, S. (2024). A Fine-Tuned Convolutional Neural Network Model for Banana Leaf Disease Detection. *2024 11th International Conference on Reliability, Infocom Technologies and Optimization (Trends and Future Directions), ICRITO 2024*. https://doi.org/10.1109/ICRITO61523.2024.10522296

Syed-Ab-Rahman, S. F., Hesamian, M. H., & Prasad, M. (2021). Citrus disease detection and classification using end-to-end anchor-based deep learning model. *Applied Intelligence 2021 52:1*, *52*(1), 927–938. https://doi.org/10.1007/S10489-021-02452-W

Tan, M., & Le, Q. V. (2019). EfficientNet: Rethinking Model Scaling for Convolutional Neural Networks. *36th International Conference on Machine Learning, ICML 2019*, *2019-June*, 10691–10700. https://arxiv.org/pdf/1905.11946

Uttam, A. K. (2022). Grape Leaf Disease Prediction Using Deep Learning. *Proceedings - International Conference on Applied Artificial Intelligence and Computing, ICAAIC 2022*, 369–373. https://doi.org/10.1109/ICAAIC53929.2022.9792739

Xie, X., Ma, Y., Liu, B., He, J., Li, S., & Wang, H. (2020). A Deep-Learning-Based Real-Time Detector for Grape Leaf Diseases Using Improved Convolutional Neural Networks. *Frontiers in Plant Science*, *11*, 529357. https://doi.org/10.3389/FPLS.2020.00751/TEXT

Xu, W., & Wang, R. (2023). ALAD-YOLO:an lightweight and accurate detector for apple leaf diseases. *Frontiers in Plant Science*, *14*, 1204569. https://doi.org/10.3389/FPLS.2023.1204569/TEXT

Zhu, S., Ma, W., Wang, J., Yang, M., Wang, Y., & Wang, C. (2023). EADD-YOLO: An efficient and accurate disease detector for apple leaf using improved lightweight YOLOv5. *Frontiers in Plant Science*, *14*, 1120724. https://doi.org/10.3389/FPLS.2023.1120724/TEXT

Apéndices

Apéndice A - Repositorio de la aplicación: código fuente completo del prototipo (estructura del proyecto, aplicación móvil, scripts de entrenamiento y conversión del modelo, e instrucciones de instalación), disponible en el repositorio de GitHub.

Apéndice B - Especificación de Requisitos de Software (ERS): documento completo elaborado según el estándar IEEE 830, con los requisitos funcionales y no funcionales del sistema. Disponible en el documento ERS.

Apéndice C - Casos de Uso (UC): especificación completa (ECUD) con actores, precondiciones, flujos principales y alternativos, y los diagramas correspondientes. Disponible en el documento de casos de uso.